

BAB 4 HASIL DAN PEMBAHASAN

(ROMBAK TOTAL)

4.1. Profil Sampel dan Pengambilan Data

Penelitian dimulai dengan melakukan pengambilan data sekunder dari Kementerian Kesehatan pada Februari 2026. Data Riset Fasilitas Kesehatan 2019 di Puskesmas yang diambil pada tahun 2018 dipilih sebagai sumber data dengan izin etik dari Komisi Etik Badan Litbang dengan nomor persetujuan etik No. LB. 02.01/2/KE/011/2019 dan Nomor Amandemen LB.02.01/2/KE.011/2019. Pemintaan data dilakukan melalui website <https://layanandata.kemkes.go.id/> di bawah naungan Pusat Data dan Teknologi Informasi Kementerian Kesehatan. Peneliti melampirkan surat permintaan yang ditujukan kepada Kepala Pusat Data dan Teknologi Informasi disertai 120 kode yang diminta yang disusul dengan pengisian *Non-Disclosure Aggrement* (NDA).

Data sekunder yang dikirimkan terdiri dari 121 Puskesmas Provinsi Daerah Istimewa Yogyakarta dan 200 Puskesmas Provinsi Maluku dengan 120 kode dataset yang menunjang informasi 60 variabel independen pada definisi operasional serta 34 dari 40 obat esensial di Puskesmas yang tersedia pada data Rifaskes 2019. Data set ini digunakan untuk mengetahui tingkat ketersediaan obat esensial di Puskesmas Provinsi Daerah Istimewa Yogyakarta dan Maluku berdasarkan *Machine Learning* dan faktor yang paling memengaruhi ketersediaan obat esensial di Puskesmas pada kedua provinsi. Ketersediaan obat sendiri memberikan peranan penting dalam meningkatkan pelayanan kesehatan di fasilitas kesehatan.

Variabel dependen pada penelitian ini adalah obat esensial di Puskesmas. Dari 40 obat esensial di Puskesmas, 6 obat diantaranya tidak tersedia pada data Rifaskes 2019, yaitu Tablet Asam Askorbat, Tablet Dihidroartemisin + piperakuin(DHP) + Primaquin, Injeksi Difenhidramin 10 mg/mL, Krim/Salep Hidrokortison, Tablet Prednison 5 mg, dan Retinol 100.000/200.000 IU sehingga kelima obat tersebut tidak dapat diteliti lebih lanjut. Meskipun

begitu, penilaian ketersediaan obat esensial dapat tetap dilakukan menilai suatu puskesmas dikatakan memenuhi ketersediaan obat esensial apabila memiliki 80% obat esensial atau 32 obat esensial.

Selain variabel dependen, variabel independen juga diambil dari sumber yang sama. Peneliti mengambil 80 kode dataset pada data Rifaskes 2019 untuk menunjang pembentukan 59 variabel independen Puskesmas dan 1 variabel independen Dinas Kesehatan. Variabel independen Dinas Kesehatan yang dimaksud adalah 35 dari 40 obat esensial di Dinas Kesehatan pada Provinsi Daerah Istimewa Yogyakarta dan Provinsi Maluku. Namun, terdapat

Universitas Indonesia

perbedaan ketersediaan data obat esensial di Puskesmas dan Dinas Kesehatan. Pada puskesmas sendiri terdapat 6 obat esensial di Puskesmas yang tidak tersedia, tetapi hanya 5 di antara 6 obat esensial di Puskesmas yang tidak tersedia di Dinas Kesehatan. Obat yang dimaksud adalah Tablet Prednison. Maka dari itu, perhitungan ketersediaan obat esensial di Dinas Kesehatan menggunakan data yang sama dengan ketersediaan data obat esensial di puskesmas, yaitu 34 dari 40 obat esensial. Hal ini dilakukan untuk menjaga kesetaraan definisi ketersediaan obat antara Puskesmas dan Dinas Kesehatan sehingga prednison dikeluarkan dari analisis untuk menghindari bias dalam perbandingan.

Data set sekunder yang didapatkan untuk menunjang penelitian memiliki keberagaman jenis data. Variabel independen direpresentasikan berupa data kategorikal maupun numerikal. Variabel seperti jumlah pasien rawat inap dan rawat jalan, jumlah puskesmas pembantu dan beberapa lainnya tersedia data berupa angka sedangkan variabel yang tersedia berupa kategori, seperti tingkat akreditasi puskesmas, pengiriman rencana kebutuhan obat atau RKO, karakteristik wilayah puskesmas dan lainnya. Namun, variasi jenis data tidak menjadi tantangan besar pada permodelan machine learning. Random forest sendiri mampu menangani data kategorik maupun numerik. Penyajian data kategorik memang cenderung lebih mudah diinterpretasikan dan disajikan dalam bentuk kelompok yang deskriptif dibandingkan data numerik.

Pengisian data sekunder yang dilakukan oleh banyak pihak dengan enumerator yang beragam pula pada setiap wilayah di setiap provinsi serta banyaknya puskesmas yang dikunjungi untuk dimintai data, hal ini membuat data yang tersedia masih memiliki inkonsistensi data dan keberadaan missing value yang terdeteksi bukan merupakan structural missing. Maka dari itu, penanganan terhadap inkonsistensi data dan missing value diperlukan untuk menjaga representasi data dan performa model.

Secara keseluruhan, data yang digunakan dalam penelitian ini tersedia dengan baik

dengan karakteristik yang cukup kompleks dengan adanya berbagai data yang tersedia, variasi tipe data, keberadaan missing value serta inkonsistensi data memunculkan tantangan tersendiri dalam proses pengolahan data. Maka dari itu, perlu adanya *preprocessing* data untuk dapat mempersiapkan data sebelum siap diolah oleh machine learningnya sehingga machine learning dapat menghasilkan model yang representatif terhadap data dengan menangkap pola terbaik.

Universitas Indonesia

4.2. *Preprocessing Data*

Data yang telah diterima selanjutnya akan melalui preprocessing data untuk mempersiapkan data sebelum digunakan untuk machine learning. Tahapan ini meliputi proses penggabungan kode sebagai bentuk penyesuaian terhadap variabel, pembersihan data, penyesuaian distribusi kelas, penanganan missing value, penanganan outlier, serta normalisasi data numerik.

Pada tahap awal pemeriksaan data, inkonsistensi data ditemukan pada dataset. Inkonsistensi data tersebut adalah adanya data yang terisi pada satu kode, tetapi tidak terisi pada kode lainnya. Setelah beberapa baris memiliki data hilang tersebut, data kembali terisi pada seluruh variabel. Kondisi ini mengindikasikan adanya kekurangan data pada penyusunan dataset yang telah diberikan. Maka dari itu, untuk memastikan inkonsistensi tersebut, dilakukan konfirmasi kepada Layanan Data, Kementerian Kesehatan Republik Indonesia sebagai pemilik etik data tersebut. Setelah dilakukan verifikasi, dataset yang lebih lengkap dikirimkan kembali yang selanjutnya digunakan untuk proses pengolahan data.

Guna meningkatkan interpretabilitas data, beberapa variabel numerik pada data set ditransformasikan ke dalam bentuk kategorikal. Transformasi ini juga dilakukan untuk menyesuaikan dataset tersedia dengan makna praktisnya. Kode yang mengalami transformasi, seperti jumlah penduduk di wilayah kerja. Berdasarkan Permenkes Nomor 19 Tahun 2024 tentang Penyelenggaraan Pusat Kesehatan Masyarakat, Puskesmas harus didirikan minimal di setiap kecamatan dengan mempertimbangkan rasio penduduk dan/atau aksesibilitas. Rasio penduduk yang dimaksud adalah 1:30.000 penduduk dimana satu puskesmas dengan 30.000 penduduk di wilayah kerja. Maka dari itu, kategorikal variabel jumlah penduduk di wilayah kerja terbentuk menjadi ≤ 30.000 penduduk dan > 30.000 penduduk. Selain itu, variabel proporsi alokasi dana kapitasi (%) tahun 2018 untuk obat dan operasional juga mengalami transformasi data dari numerik menjadi kategorik. Pasalnya pada Permenkes Nomor 21 Tahun

2016 tentang Penggunaan Dana Kapitasi Jaminan Kesehatan Nasional, Fasilitas Kesehatan Tingkat pertama dimana salah satunya adalah puskesmas maksimal menggunakan dana kapitasi untuk pembayaran jasa pelayanan kesehatan untuk obat dan operasional sebesar 40% dari keseluruhan penerimaan kapitasi. Oleh karena itu, skala kategorikal variabel ini menjadi $\leq 40\%$ dan $> 40\%$. Langkah preprocessing ini juga dapat menekan penghapusan data yang diakibatkan adanya data pencilan dan meningkatkan interpretabilitas data dibandingkan menggunakan data numerik mentah.

Universitas Indonesia

Preprocessing data juga melalui tahap pembersihan data. Hal ini perlu dilakukan untuk meningkatkan kualitas data dengan mengidentifikasi kesalahan ataupun ketidakkonsistenan data yang sudah terkumpul. Pengecekan duplikat data dilakukan untuk memastikan tidak adanya data satu puskesmas terinput lebih dari sekali yang dapat mempengaruhi kualitas data. Pengecekan ini dilakukan dengan melihat kode ID_Puskesmas sebagai nomor urut data puskesmas yang dikirimkan, B1R1 sebagai kode provinsi, B1R2 sebagai kode kabupaten/kota dan B1R5 sebagai kode puskesmas. Dari proses pengecekan, tidak ada duplikat data yang dapat mempengaruhi kualitas data.

Kumpulan data selanjutnya dilakukan pengecekan kode demi kode untuk memastikan konsistensi pengisian data. Namun, ditemukan adanya inkonsistensi data pada dataset. Inkonsistensi pengisian ini ditemukan pada kode B122R5 dan B122R6. Kedua kode ini merepresentasikan terpenuhi atau tidaknya obat yang dipesan melalui e-purchasing oleh puskesmas serta besaran persen terealisasinya pengadaan obat tersebut apabila tidak terpenuhi. Pada B122R6 jelas tertulis pertanyaan ‘Bila tidak, berapa persen realisasi pengadaan obat lewat e-purchasing dari total obat yang dipesan’ Tidak ini merujuk pada B122R5 yang menanyakan ‘Apakah semua obat yang dipesan lewat e-purchasing dapat dipenuhi’. Namun, terdapat beberapa puskesmas yang menjawab B122R5 dengan ‘Ya’, tetapi tetap mengisi B122R6. Lalu berdasarkan Pedoman Pengisian Kuesioner Puskesmas Rifaskes 2019, obat dipesan melalui e-purchasing yang dimaksud pada kode B122R5 dan B122R6 adalah obat yang dipesan melalui dana kapitasi. Hal ini berkaitan dengan kode B122R3 mengenai mekanisme pembelian obat dan alat kesehatan dari dana kapitasi dimana salah satu kategori kode tersebut adalah tidak ada pembelian dengan dana kapitasi. Maka dari itu, puskesmas tanpa pembelian dengan dana kapitasi untuk obat dan alkes pada kode B122R3, tidak dapat mengisi B122R5 dan B122R6. Hal yang sama terjadi pula pada kode B122R5 dan B122R6 kembali berkaitan dengan kode B122R4A. Pasalnya pada kode B122R4A merepresentasikan metode pembelian obat dan alat kesehatan dari dana kapitasi

merepresentasikan metode pembelian obat dan alat kesehatan dari dana kapitasi menggunakan metode e-purchasing sehingga puskesmas yang mengisi B122R4A dengan jawaban ‘Tidak’ atau88 ‘Tidak Tahu’ tidak dapat mengisi B122R5 dan B122R6. Namun, terdapat puskesmas yang kerap mengisi B122R5 dan B122R6 saat ditelusuri lebih jauh melalui kode B122R4A puskesmas tersebut tidak atau tidak tahu dalam melakukan pembelian dengan *e-purchasing*. Maka dari itu, dilakukan penyesuaian terhadap inkonsitenan untuk menjaga alur dan logika pengisian kuesioner sesuai dengan pedoman kuesioner yang telah ditetapkan tanpa mengganti data dan hanya mengisi kelengkapannya saja.

Universitas Indonesia

Pada dataset tersedia, sebanyak 80 kode observasi diolah kembali untuk mempermudah analisis. dan dapat merepresentasikan variabel lebih informatif. Penggabungan kode ini juga menyesuaikan dengan variabel yang ada sehingga pembacaan hasil prediksi machine learning lebih mudah terbaca. Penggabungan kode yang dilakukan, seperti pada variabel pengiriman rencana kebutuhan obat puskesmas. Berdasarkan kode rifaskes, tujuan rencana kebutuhan obat disampaikan direpresentasikan dari dua kode, yaitu B121R3A melalui Dinkes kab/kota dan B121R3B langsung ke e-monev. Penggabungan kode ini dilakukan karena didasarkan ketersediaan data pada data set rifaskes 2019 itu sendiri. Selain pengiriman rencana kebutuhan obat, variabel ruangan farmasi di puskesmas juga dilakukan penggabungan kode. Kode B6R1LK2, B6R1LK3, B6R1LK4, B6R1LK5, dan B6R1LK6 merepresentasikan kondisi ruangan farmasi di puskesmas, seperti ada atau tidaknya ruangan farmasi, tersendiri atau bergabungnya ruangan farmasi dengan ruangan lain dan kondisi ventilasi, kebersihan, dan pencahayaan ruangan. Hal ini dilakukan untuk dapat lebih menggambarkan keadaan ruangan farmasi yang menjadi salah satu penyimpanan obat dimana penyimpanan obat ini dapat berpengaruh pada ketersediaan obat esensial. Maka dari itu, data awal yang akan digunakan sejumlah 60 variabel atau fitur dengan 318 puskesmas atau baris

Pengecekan statistik deskriptif awal dilakukan untuk melihat persebaran data lebih lanjut guna memastikan kualitas data. Pengecekan akan membandingkan mean atau rata-rata, standar deviasi, nilai pada kuartil pertama, kedua, dan ketiga. Pada data awal terlihat bahwa seluruh variabel numerik memiliki distribusi tidak normal. Maka dari itu, perlu adanya tahapan preprocessing lainnya untuk meningkatkan kualitas data dengan melihat permasalahan masing-masing variabel.

Gambar. Statistik Deskriptif Data Awal

	B3R13A	B4R14	B4R16A	B14R23	B1282R2
--	--------	-------	--------	--------	---------

mean	2.6125	64602.25625	24136.21429	20687.9281	21.76
std	2.998406	196929.9615	144111.4969	27896.1579	125.088
min	0	130	0	0	0
25%	1	2006.75	33.75	2364.5	2
50%	2	9496.5	142.5	9344.5	2
75%	4	34091.25	316.75	23796.5	3

Universitas Indonesia

max	44	888888	888888	90304	888
-----	----	--------	--------	-------	-----

Pada variabel B3R13A yang merepresentasikan jumlah puskesmas pembantu di wilayah kerja puskesmas memiliki nilai minimum 0, nilai maksimum 44 dan standar deviasi 2.9. Nilai ini cukup besar jika dibandingkan mayoritas data. Hal ini menunjukkan adanya variasi data yang besar. Nilai maksimum dengan rentang nilai jauh dibandingkan nilai kuartil tiga atau 75% juga mengindikasikan kemungkinan adanya pencilan pada data tersebut.

Variabel jumlah peserta penerima bantuan iuran atau PBI di puskesmas dengan kode B14R23 dan variabel frekuensi penerimaan obat dari Kementerian Kesehatan dengan kode B1282R2 juga memiliki tantangan yang sama. Nilai maksimum dengan nilai kuartil 3 atau 75% yang terlampaui jauh menandakan persebaran data yang luas sehingga adanya nilai ekstrem pada data observasi. Perbedaan pada nilai mean dan median juga menunjukkan adanya distribusi yang tidak normal atau merata pada variabel tersebut.

Kejanggalan terjadi pada kode B4R14 dan B4R16A yang merepresentasikan variabel jumlah kunjungan pasien rawat jalan dan rawat inap. Pasalnya adanya perbedaan ekstrim antara mean dan median serta nilai kuartil 75% dan nilai maksimum. Distribusi kedua data tidak simetris dan mengarah pada distribusi *right-skewed*. Hal ini dapat mempengaruhi proses pembelajaran dalam pembentukan model dan adanya kecenderungan berbagai variabel. Namun setelah ditelusuri, nilai 888.888 memiliki makna tertentu pada data, yaitu tidak adanya data. Ketidakadaan data ini berasal dari narasumber atau puskesmas itu sendiri. Maka dari itu, nilai 888.888 akan dihapus dan akan diimputasi. Setelah nilai 888.888 dihapus dan akan diimputasi, data menjadi tidak terlalu ekstrem, tetapi data masih perlu adanya penanganan. Hal ini juga terbukti pada diagram di bawah bahwa pada kode B4R14 masih terdapat data pencilan setelah dilakukannya penyesuaian pada ketidaktersediaan data. Maka dari itu, penanganan lebih lanjut diperlukan.

Gambar. Statistik Deskriptif Setelah Penanganan Ketidakadaan Data

	B3R13A	B4R14	B4R16A	B14R23	B1282R2
mean	2.6125	18324.38079	225.70642	20687.9281	21.76
std	2.998406	23941.41556	1097.8259	27896.1579	125.088
min	0	130	0	0	0
25%	1	1908.25	33	2364.5	2
50%	2	8125.5	129	9344.5	2

75%	4	28788.75	306	23796.5	3
max	44	260060	9263	90304	888

Pada data mentah dari Kementerian Kesehatan masih terdapat beberapa data dengan kekosongan nilai. Hal ini dapat mempengaruhi terbentuknya model karena adanya kecenderungan terhadap variabel tertentu. Maka dari itu untuk menjaga proporsi data, penanganan missing value akan menggunakan berbagai metode untuk menyesuaikan data guna menjaga data yang ada.

Tabel. Variabel dengan *Missing Value*

Variabel	Jumlah Missing	Persentase Missing	Penanganan
Asiklovir Tablet (B1281R41K3)	1	0.31%	Penghapusan Baris
Natrium Diklofenak Tablet (B1281R233K3)	1	0.31%	Penghapusan Baris
Bendahara Dana Kapitasi JKN (B14R2)	2	0.63%	Penghapusan Baris
Ketersediaan SDM Apoteker (B14R15BTERSEDIA)	2	0.63%	Penghapusan Baris
Penanggung jawab ketersediaan obat (B1282R6)	1	0.31%	Penghapusan Baris
Pedoman Pengelolaan Obat (B8R2K4N)	4	1.25%	Penghapusan Baris
Ruangan farmasi di puskesmas (B6R1LK4)	1	0.31%	Penghapusan Baris
Proporsi alokasi dana kapitasi (%) tahun 2018 untuk obat dan	2	0.63%	Penghapusan Baris

tahun 2018 untuk obat dan operasional (B14R13B)			
Pendidikan Kepala Puskesmas (B51R1B)	1	0.31%	Penghapusan Baris
Pedoman Sistem Informasi Manajemen Kesehatan (B8R2K4O)	6	1.88%	Penghapusan Baris
Ketersediaan Obat Non Fornas dan Fornas non e-katalog	1	0.31%	Penghapusan Baris

Universitas Indonesia

(B123R1)			
Penerapan KBK di Puskesmas (B14R16)	2	0.63%	Penghapusan Baris
Periode Suplai Obat dari Kemenkes (B1282R2)	1	0.31%	Penghapusan Baris
Jumlah Kunjungan Pasien Rawat Jalan (B4R14)	16	5.02%	Imputasi
Jumlah Peserta PBI di Puskesmas (B14R23)	37	11.60%	Imputasi
Jumlah Kunjungan Pasien Rawat Inap (B4R16A)	3	0.94%	Imputasi
Pemenuhan Pengadaan Obat melalui <i>e-purchasing</i> (B122R5)	20	6.27%	Imputasi
Persentase Pemenuhan Pengadaan Obat melalui <i>e-purchasing</i> (B122R6)	25	7.84%	Imputasi

Berdasarkan data yang tersedia, missing value terdapat pada berbagai variabel. Penyesuaian penanganan diperlukan untuk memastikan kualitas data terjaga tanpa mengurangi banyak data secara signifikan. Pada data kategorik akan diterapkan metode *listwise deletion* untuk data dengan kekosongan nilai $< 5\%$ dari keseluruhan baris atau sebanyak < 16 baris. Namun, untuk variabel kategorik dengan proporsi missing value $\geq 5\%$ akan diperlakukan pembuatan kategorik baru sebagai kategori “Tidak Tahu”. Hal ini dilakukan untuk menghindari bias pada model tanpa menimbulkan noise yang membuat model sulit belajar pola.

Akan tetapi, untuk missing value pada data numerik akan diperlakukan metode

imputasi karena data numerik dengan pola kontinu dapat diperkirakan nilai yang hilang berdasarkan hubungannya dengan variabel lain dibandingkan data kategorik. Imputasi ini akan dilakukan untuk semua data numerik yang memiliki missing value. Langkah ini dilakukan untuk mempertahankan informasi untuk pembuatan model tanpa mengurangi kehilangan data berlebih karena penghapusan data.

Imputasi pada data numerik dengan kehilangan data akan diatasi menggunakan metode *Multiple Imputation by Chained Equations* atau MICE. Metode ini akan mengisi data yang hilang berdasarkan hubungannya dengan variabel lain. Penggunaan variabel lain ini

Universitas Indonesia

menjadi salah satu alasan kuat penggunaannya dibandingkan penggunaan *simple imputation* yang hanya menggunakan nilai rata-rata, nilai tengah, atau nilai yang paling sering muncul. MICE dapat menghasilkan imputasi yang realistis dengan mengaitkan korelasi antar data.

Multiple Imputation by Chained Equations atau MICE akan bekerja dengan mengisi sementara nilai kosong dalam data dengan mean, median atau modus karena mice memerlukan dataset yang lengkap untuk mempelajari hubungan antarvariabel. Lalu, salah satu variabel dengan nilai kosong akan dipilih untuk diisi nilai kosongnya dan menjadikan variabel lainnya sebagai prediktor sehingga nilai kosong dapat terisi. Hal ini juga dilakukan pada variabel yang lain dan terus menerus sampai nilai kosong dapat terisi dan bersifat stabil stabil dan konvergen dengan perubahan nilai yang tidak drastis kembali (SITASI).


Metode imputasi MICE ini akan memprediksi nilai kosong pada variabel Jumlah Kunjungan Pasien Rawat Jalan (B4R14), Jumlah Peserta PBI di Puskesmas (B14R23), dan Jumlah Kunjungan Pasien Rawat Inap (B4R16A). Dengan metode ini, nilai kosong pada ketiga variabel tersebut dapat diisi. Hasil imputasi ini memerlukan adanya evaluasi kembali untuk menilai apakah MICE dapat memprediksi nilai berdasarkan variabel dan data set yang ada. Matrik evaluasi yang dipilih untuk mengevaluasi hasil MICE adalah MAE atau *Mean Absolute Error* dan RMSE atau *Root Mean Square Error*. *Mean Absolute Error* atau MAE adalah nilai yang menggambarkan rata-rata kesalahan perbedaan nilai prediksi dan nilai aktualnya tanpa melihat arah kesalahannya sedangkan *Root Mean Square Error* adalah nilai yang menggambarkan kesalahan yang terdistribusi dan menitikberatkan pada kesalahan besar dalam hasil imputasi. RMSE ini menjadi metrik umum yang digunakan untuk mengevaluasi kualitas imputasi guna memastikan data yang diimputasi memiliki akurasi prediksi terbaik (SITASI). MAE dan RMSE dikatakan baik apabila mendekati 0. Namun, untuk saling melengkapi melihat rata-rata kesalahan secara umum, MAE juga digunakan sebagai penunjang matriks evaluasi. Keduanya ini kerap digunakan untuk meneliti hasil prediksi

karena sifatnya yang komplementer.

Berdasarkan penelitian yang sudah dilakukan, Nilai MAE dan RMSE dari metode MICE adalah berturut-turut 0.1631 dan 0.2323. Nilai ini lebih baik dibandingkan dengan MAE dan RMSE metode KNN, yaitu berturut-turut sebesar 0.2323 dan 0.3072. Berdasarkan hasil tersebut, metode imputasi MICE memiliki kualitas imputasi lebih baik dibandingkan metode KNN. Hal ini terlihat jelas pada nilai MAE dan RMSE metode MICE lebih kecil dibandingkan KNN dimana ini menunjukkan bahwa MICE lebih mampu mengatasi kesalahan

Universitas Indonesia

di proses imputasi dan menghasilkan nilai imputasi yang lebih stabil dan lebih mendekati nilai sebenarnya.



Gambar. Perbandingan Nilai MSE dan RMSE metode MICE dan KNN


Hasil imputasi baik juga dibuktikan dari statistik deskriptif data tersebut. Pasalnya setelah imputasi MICE, ketiga variabel menunjukkan tidak adanya perubahan signifikan pada nilai rata-rata, median, standar deviasi dan nilai pada kuartil 3. Distribusi ketiga variabel juga relatif konsisten. Hal ini menunjukan bahwa imputasi tidak merusak distribusi data sebelumnya, dapat mempertahankan karakteristik distribusi data, dan imputasi tidak menghasilkan nilai absurd??. Maka dari itu, metode MICE dipilih untuk mengatasi *missing data* karena tidak menyebabkan distorsi ditribusi data secara ekstrem.

Tabel. Statistik Deskriptif Setelah Imputasi

	B4R14	B4R16A	B14R23
mean	18324.38079	250.64183	10927.1313
std	23310.53417	672.53467	12011.86866

std	25516.95417	672.95467	12611.86666
min	130	0	0
25%	1976	33	2262
50%	7936	140	7265
75%	25931	275	16317
max	260060	6959	90304

Selanjutnya, data yang sudah diimputasi *missing value*-nya akan diproses lebih lanjut karena pada data ditemukan adanya pencilan yang didukung dengan visualisasi grafik *boxplot* pada Gambar. ??? bahwa pada keseluruhan data numerik memiliki nilai pencilan yang perlu ditangani. Penanganan nilai pencilan akan menggunakan metode Interquartile Range atau IQR. Metode ini dapat mendeteksi nilai ekstrem secara cepat dan tidak terikat pada penyebaran data yang ada. Sebelumnya data akan diurutkan berdasarkan ranking dan dibagi menjadi empat bagian sama besar yang disebut sebagai kuartil. Nilai yang membagi setiap bagian disebut dengan Q1, Q2, dan Q3. Q1 dan Q3 adalah nilai tengah di setengah pertama dan setengah kedua data yang sudah berurutan sedangkan Q2 adalah nilai tengah dari keseluruhan data. Nilai interquartile sendiri dinilai sebagai selisih antara kuartil ke-3 (Q3) dan kuartil pertama (Q1). Nilai ini akan dijadikan titik kunci untuk mengkategorikan apakah nilai dari suatu data dikatakan sebagai pencilan atau tidak. Suatu nilai dikatakan pencilan apabila berada di luar rentang ($Q1 - 1,5 \times \text{rentang interquartile}$) sebagai batas bawah atau *lower bound* hingga ($Q3 + 1,5 \times \text{Rentang interquartile}$) sebagai batas atas atau *upper bound*.



Gambar. Variabel Numerik Sebelum Penanganan Pencilan


Setelah nilai pencilan terdeteksi, penanganan berupa winsorizing dilakukan untuk mengurangi efek pencilan terhadap data set. Winsorizing dipilih karena dapat mengurangi nilai ekstrem tanpa menghapus data observasi sehingga data dengan informasi penting tetap dapat terjaga. Winsorizing dapat menjaga banyak data yang akan digunakan untuk membuat model sehingga model dapat memiliki informasi yang cukup. Winsorizing atau teknik capping menangani pencilan dengan menggantikan nilai tersebut dengan batas bawah atau batas atas dari IQR. Nilai pencilan yang berada di atas batas atas akan digantikan dengan nilai

Universitas Indonesia

batas atas tersebut sedangkan nilai pencilan yang berada di bawah batas bawah akan digantikan dengan nilai batas bawah itu sendiri

Sebagai contoh dalam penanganan pencilan pada kode B3R13A yang merepresentasikan jumlah puskesmas pembantu. Nilai dari Q1, Q2, dan Q3-nya adalah 1, 2, dan 4. Nilai dari IQR adalah 3 yang didapatkan dari $Q3 - Q1 = 4 - 1 = 3$. Maka dari itu, batas bawah atau *lower bound* dari variabel ini adalah - 3,5 dengan batas atas atau *upper bound* sebesar 8,5. Berdasarkan hasil tersebut, nilai yang berada di atas 8,5 seperti 10, 11, dan 44 merupakan outlier sehingga nilai tersebut akan digantikan dengan nilai *upper bound* untuk mengeliminasi pencilan dan tetap mempertahankan nilai untuk variabel lainnya.

Perlakuan IQR dan winsorizing juga dilakukan untuk variabel numerik lainnya, seperti pada variabel jumlah peserta penerima bantuan iuran atau PBI, periode suplai obat dari kementerian kesehatan, jumlah kunjungan pasien rawat jalan dan jumlah kunjungan pasien rawat inap. Guna memastikan tidak adanya pencilan setelah perlakuan IQR dan winsorizing, visualisasi menggunakan grafik boxplot dilakukan. Berdasarkan grafik tersebut terbukti ketiadaan pencilan dalam data.



Gambar. Variabel Numerik Setelah Penanganan Pencilan

Penanganan pencilan ini juga memperbaiki distribusi data yang ada. Persebaran data

yang dihasilkan dari penanganan outlier menjadi lebih stabil. Hal ini dapat terlihat dari adanya penurunan standar deviasi dan nilai maksimum secara signifikan. Nilai rata-rata juga mendekati nilai median dan range data mengecil menandakan distribusi lebih seimbang dan variasi ekstrem berkurang. Winsorizing membantu mempertahankan data, mengurangi nilai ekstrem tanpa menghilangkan data berlebihan.

Gambar. Statistik Deskriptif Penanganan Pencilan dengan Winsorizing

	B3R13A	B4R14	B4R16A	B14R23	B1282R2
--	--------	-------	--------	--------	---------

mean	2.548544	16482.00425	186.68012	10461.6313	2.46875
std	1.881016	17963.41878	181.04234	10231.5504	1.21343
min	0	130	0	0	0
25%	1	1976	33	2262	2
50%	2	7936	140	7265	2
75%	4	25931	275	16317	3
max	8.5	61863	637	37399	4


Subset data yang sudah siap dijalankan akan dilakukan data *scaling* dengan mengubah nilai dari fitur-fitur dan tetap mempertahankan skala data awal. Data *scaling* ini juga dilakukan untuk menjaga pembuatan model machine learning condong lebih besar pada variabel dengan nilai yang lebih besar. Maka dari itu, data numerik dengan rentang nilai yang berbeda-beda akan dilakukan pengecilan rentang yang mempertahankan skala data awal dan menyamaratakan rentang nilai antar variabel numerik.

Metode *scaling* memiliki berbagai macam jenis tergantung penggunaannya. Metode *scaling* data yang kerap digunakan, seperti *standard scaling* dan *minmax scaling* atau *normalisasi scaling*. Pada penelitian ini, penulis menggunakan metode *min-max scaling* untuk menormalisasi data. Metode *Min-Max Scaling* akan mengubah rentang data dalam rentang $[0,1]$ dimana nilai terkecil akan menjadi 0 dan nilai terbesar menjadi 1. Hal ini bertujuan agar semua variabel memiliki skala yang sama. *Min-Max Scaling* terbukti kerap menghasilkan akurasi tinggi pada model. Pada beberapa artikel dipaparkan bahwa *Min-Max scaling* menghasilkan akurasi tertinggi pada model dibandingkan *Z-Score* atau *standard scaling* dan *decimal scaling* (SITASI). Metode *Min-Max Scaler* dapat mempertahankan distribusi asli data. Selain itu, ia juga lebih dipilih karena dataset yang dimiliki peneliti memiliki rentang

nilai berbeda-beda sehingga perlu adanya penyamaan skala untuk mencegah adanya dominasi pada salah satu variabel dengan rentang nilai yang besar.

Meskipun model Random Forest dan XGBOOST membentuk model berdasarkan pohon keputusan sehingga tidak membutuhkan scaling, proses ini tetap dilakukan guna nilai pada data dapat lebih terstandarisasi dengan rentan yang konsisten antar variabel numerik sehingga dapat mempermudah interpretasi hasil evaluasi. Selain itu, berdasarkan grafik histogram terbukti bahwa Min-Max Scaler tidak merubah nilai pada dataset secara bermakna, tetapi hanya mengubah rentang datanya dalam rentang 0-1.

Universitas Indonesia



Gambar. Grafik B14R23 Sebelum dan Sesudah Scaling

Selain variabel numerik yang dilakukan penyesuaian data, tetapi variabel kategorikal juga dilakukan proses encoding. Teknik encoding untuk variabel kategorik yang kerap digunakan, seperti label encoding dan one hot encoding. Pada penelitian ini digunakan label encoding dengan mengubah data kategorikal menjadi numerik pada data kategorikal berupa ordinal. Langkah ini untuk menunjukkan adanya urutan pada kategorikal tersebut serta dapat merepresentasikan kategorik yang dimaksud karena algoritma *machine learning* kerap bekerja lebih baik pada data numerik dibandingkan data kategorik. Selain itu, pemilihan metode ini juga didasarkan pada sebagian besar data yang sudah berbentuk kategori dengan berbentuk label encoding.

Teknik One Hot Encoding juga diterapkan pada variabel kategorikal dengan mengubahnya menjadi bentuk biner. One Hot Encoding akan membuat semua variabel memiliki nilai nol kecuali pada puskesmas yang sesuai dengan kategorinya yang akan diisi dengan angka 1. Sebagai contoh pada kode B3R3 yang merepresentasikan variabel kategori puskesmas berdasarkan kemampuan pelayanan akan memiliki dua kolom sesuai dengan item data yang dikodekan, yaitu 1 adalah puskesmas rawat inap dan 2 adalah puskesmas non rawat inap. Kolom 1 pada B3R3 akan diisi 1 oleh puskesmas rawat inap dan berisi 0 untuk puskesmas non rawat inap maupun sebaliknya. Kolom 2 pada B3R3 akan berisi 1 oleh

puskesmas non rawat inap dan berisi 0 untuk puskesmas rawat inap. Pengaplikasian teknik ini guna tidak menciptakannya urutan palsu dan membantu model lebih akurat memahami kategori lebih baik tanpa berasumsi tidak tepat mengenai hubungan antar kategori.

Seluruh tahapan preprocessing telah dilakukan untuk dapat mempersiapkan dataset menuju proses pemodelan *machine learning*. Dengan ini diharapkan data yang akan diproses *machine learning* merupakan data terbaik yang dapat menunjang model mempelajari pola data secara optimal. Selanjutnya, data akan dinalisis menggunakan algoritma Random Forest dan XGBoost. Keduanya akan digunakan untuk menghasilkan faktor-faktor yang paling

Universitas Indonesia

memengaruhi ketersediaan obat esensial di Puskesmas Provinsi Daerah Istimewa Yogyakarta dan Provinsi Maluku.

4.3. Analisis Data

YANG RIIL

4.3.1. Pemodelan dan Evaluasi *Machine Learning*

Sebanyak 16 percobaan dilakukan dengan 2 jenis data, 2 algoritma *machine learning*, dan 4 metode *splitting data*. Keseluruhan percobaan yang dilakukan memperoleh parameter terbaik. Parameter terbaik tersebut diujikan pada data pengujian dan matriks evaluasi dianalisis untuk melihat tingkat kesesuaian model. Proses pada data pengujian dan pelatihan ini juga dilakukan *repeated holdout*. Metode ini akan mengulang proses pelatihan dan pengujian selama lima kali dengan nilai *random state* yang berbeda-beda. *Random state* sendiri adalah parameter yang akan menjaga pengacakan dataset sebelum dilakukan *splitting data*. Penentuan nilai *random state* akan menjaga pengacakan data secara konsisten setiap kode dijalankan karena *random state* akan menjaga pembagian dataset. *Repeated holdout* mengulang proses untuk dapat menghasilkan model yang lebih stabil dengan nilai performa akan dirata-ratakan untuk melihat kestabilan model pada *splitting data* yang berbeda-beda.

Matriks evaluasi akan menilai kinerja model dalam memprediksi variabel target dengan matriks yang digunakan pada penelitian ini adalah akurasi, *matthew correlation coeficient*, *area under the precision-recall curve* dan *area under the receiver operating characteristic curve*. Penggunaan keempat matriks ini saling melengkapi untuk menunjang interpretasi kualitas model terpilih dan evaluasi [CN1] lebih komprehensif. Akurasi digunakan untuk melihat proporsi prediksi benar yang sudah dilakukan model, MCC atau *Matthews Correlation Coefficient* digunakan untuk mengukur kuat hasil prediksi model

dengan kondisi sebenarnya yang mempertimbangkan *confusion matrix*. AUROC dapat mengukur kualitas model untuk membedakan kelas tersedia dan kelas tidak tersedia sedangkan AUPRC berfokus pada kelas positif dan seberapa sering prediksi tersebut benar.

Tabel 17. Matriks Evaluasi *Random Forest*

Baseline				Hasil Preprocessing			
<i>Rando</i> <i>m</i>	Provins i	KM: Intra	KM: Ekstra	<i>Rando</i> <i>m</i>	Provins i	KM: Intra	KM: Ekstra

Mea n	Akurasi	0.80968	0.89355	0.84193	0.79395	0.80968	0.88387	0.87096	0.80827
				5	3			8	4
	MCC	0.60962	0.78006	0.67944	0.34725	0.60722	0.75972	0.73425	0.57799
				0	5			2	1
	AUPRC	0.82873	0.88931	0.86116	0.74550	0.83570	0.89493	0.88252	0.81761
STD				2	3			4	0
	AURO C	0.88065	0.94516	0.90668	0.77911	0.88238	0.94409	0.91878	0.83294
				6	8			7	7
	Akurasi	0.03678	0.04048	0.04174	0.07066	0.03102	0.03497	0.05469	0.05815
				9	9			6	3
STD	MCC	0.08046	0.07287	0.08988	0.21968	0.06667	0.06477	0.11651	0.111469
				8	4			5	
	AUPRC	0.08910	0.04476	0.06312	0.18145	0.07585	0.03758	0.11796	0.05401
				0	5			2	3
	AURO C	0.05229	0.02244	0.03466	0.09286	0.05110	0.02386	0.06910	0.02885
				4	9			6	9

Tabel 18. Matriks Evaluasi *XGBoost*

		Baseline				Hasil Preprocessing			
		<i>Rando</i>	Provins	KM:	KM:	<i>Rando</i>	Provins	KM:	KM:
		<i>m</i>	i	Intra	Ekstra	<i>m</i>	i	Intra	Ekstra
Mea n	Akurasi	0.79677	0.86774	0.83225	0.78978	0.81290	0.88387	0.85161	0.804943
				8	6			3	
	MCC	0.58140	0.71654	0.66432	0.34005	0.61555	0.76168	0.69673	0.558943
				8	5			6	
	AUPRC	0.83137	0.83995	0.84193	0.73337	0.82087	0.89578	0.85699	0.840487
STD				9	9			8	
	AURO C	0.87460	0.92145	0.89299	0.76608	0.87568	0.94586	0.89384	0.838100
				0	8			2	

STD	Akurasi	0.04919	0.03103	0.03344	0.07514	0.03345	0.03851	0.05969	0.041532
				6	8			9	
	MCC	0.10547	0.05523	0.07399	0.23621	0.07250	0.06742	0.12400	0.117924
				4	7			3	
	AUPRC	0.07482	0.02689	0.08179	0.18660	0.06929	0.02655	0.09936	0.049453
				1	9			5	
	AURO	0.04591	0.01692	0.04037	0.12241	0.04735	0.01916	0.06622	0.029471
	C			3	4			8	

4.3.1.1. Pengaruh *Splitting Data* Terhadap Model

Splitting Data dilakukan dengan tiga strategi, yaitu *random sampling*, *stratified sampling* provinsi dan *cluster* berdasarkan kemiripan karakteristik. *Random sampling* memiliki performa standar sebagai *baseline* diantara ketiga strategi. Keseluruhan matriks evaluasinya konsisten menjadi *baseline* yang mana salah satunya tervisualisasi pada Gambar 24 bahwa nilai AUROC pada algoritma *random forest* maupun *XGBoost*. *Random split* masih dapat mempertahankan performanya meskipun secara konsisten performanya tidak setinggi strategi *splitting* data lainnya.

Gambar 25. Perbandingan Nilai AUROC Berdasarkan Metode Stratifikasi

Strategi berdasarkan *cluster* yang memanfaatkan *k-means* juga menghasilkan performa yang cukup baik. Pendekatan *intra-cluster* memiliki performa lebih baik dibandingkan *ekstra cluster*. Hal ini konsisten pada seluruh data dan algoritma yang terjadi karena dari 5 cluster yang terbentuk, masing-masing bagian *cluster* terbagi menjadi data pelatihan dan data pengujian sehingga *best* model yang terbentuk mempelajari pola dengan baik pada data pelatihan dan data pengujian yang tersedia memiliki kemiripan karakteristik dengan data pelatihan. Berbanding terbalik dengan *ekstra-cluster* yang konstan memiliki performa tidak lebih baik dibandingkan *intra cluster* karena data pengujian adalah data baru yang tidak dipelajari atau dilihat model pada proses training. Namun, *ekstra-cluster* pada beberapa model memiliki performa yang tidak jauh berbeda dengan stratifikasi berdasarkan target walaupun tetap terjadi adanya penurunan pada *ekstra-cluster* seperti pada data hasil *preprocessing* algoritma *random forest*. Hal ini menunjukkan bahwa model yang terbentuk tetap belajar pola generalisasi dari data pelatihan dan bukan hanya menghafal data karakteristik *cluster* pada data pelatihan.

Gambar 26. Perbandingan *Intra-Cluster* & *Ekstra-Cluster* pada Nilai Akurasi dan AUPRC

Performa terbaik dimiliki oleh stratifikasi berdasarkan provinsi. Pada stratifikasi berdasarkan provinsi, konsisten pada keseluruhan matriks evaluasi memiliki performa terbaik dibandingkan ketiga strategi *splitting* data lainnya. Di mana *baseline* model *random forest*, Akurasi model mencapai 0,89355 dengan MCC 0,78006; AUPRC 0,88931 dan AUROC 0.94516. Akurasi yang tinggi menandakan bahwa 89,3% data dapat model prediksi dengan baik dengan model yang terbentuk tidak bias pada salah satu kelas yang dibuktikan dengan MCC yang mendekati +1. Selain itu, AUPRC dan AUROC yang tinggi juga membuktikan

Universitas Indonesia

bahwa model dapat memprediksi kelas positif dengan baik dan dapat membedakan dengan baik kedua kelas target.

Performa terbaik yang dimiliki stratifikasi berdasarkan provinsi membuktikan bahwa adanya karakteristik yang jelas pada masing-masing provinsi Daerah Istimewa Yogyakarta dan Maluku dimana hal ini menguntungkan karena dapat mempertahankan pola yang relevan pada variabel independen terhadap ketersediaan obat.

Gambar 27. Perbandingan Nilai Akurasi dan MCC Berdasarkan Stratifikasi

Secara keseluruhan, kedua algoritma memberikan performa yang konsisten pada masing-masing strategi *splitting* data. *Splitting* data secara nyata memberikan perubahan performa pada model di *random forest* maupun *XGBoost*. Performa tertinggi dimiliki oleh stratifikasi berdasarkan provinsi, diikuti oleh stratifikasi berdasarkan *cluster* dan stratifikasi berdasarkan target yang dijadikan target. Hal ini menunjukkan bahwa perbedaan karakteristik data pada data pelatihan dan data pengujian menjadi peran kunci untuk model dapat memprediksi ketersediaan obat dengan baik.

4.3.1.2. Analisis Performa Algoritma dan Pemilihan Model Terbaik

Secara garis besar, kedua algoritma memberikan performa yang baik dengan nilai yang berdekatan pada beberapa kondisi uji, tetapi tetap terdapat beberapa perbedaan antara kedua algoritma dalam merespon data. Pada *random forest* sendiri, Nilai rata-rata AUPRC dan AUROC-nya konstan lebih tinggi dibandingkan *XGBoost*. Hal ini menandakan bahwa *random forest* lebih andal untuk mendeteksi kelas tersedia pada data dan juga dapat membedakan kelas tersedia dan tidak tersedia dengan baik dibandingkan *XGBoost* sedangkan untuk matriks evaluasi lainnya.

Gambar 28. Perbandingan Matriks Evaluasi antara *Baseline* dan *Preprocessing*

Pada Gambar 29 menunjukkan bahwa pada *random sampling*, penerapan *preprocessing* menghasilkan perubahan performa yang kecil dibandingkan dengan *baseline*. Pada AUROC dan AUPRC hanya terjadi sedikit kenaikan, yaitu sebesar 0,00697 pada AUPRC dan 0,00173 pada AUROC. Selain itu, terjadi penurunan pada nilai MCC sebesar 0,0024 dan nilai akurasi yang bernilai tetap. Hasil ini menunjukkan bahwa *preprocessing* tidak menghasilkan peningkatan performa yang signifikan dan tidak bertindak konsisten pada seluruh matriks evaluasi. Namun, terjadi perubahan tampak jelas pada stratifikasi provinsi. Pasalnya terjadi penurunan pada sebagian besar matriks evaluasinya, seperti akurasi, MCC, dan AUROC.

Universitas Indonesia

Preprocessing memberikan dampak penurunan pada sebagian besar matriks evaluasi. Di mana perlakuan *Winsorization* menggunakan IQR dengan merubah nilai pencilan memberikan perubahan pada matriks berupa sedikit penurunan performa. Hal ini mengindikasikan bahwa variasi antarprovinsi memiliki informasi kuat membedakan ketersediaan obat esensial pada data pencilan yang mengalami perubahan dengan *winsorization* (Leone et al., 2019). Walaupun begitu, perubahan yang terjadi sangatlah kecil dan tidak bertindak konsisten karena AUPRC mengalami kenaikan yang mengindikasikan bahwa model dapat memprediksi kelas positif atau kelas tersedia dengan baik. Selain itu, *random forest* sendiri cenderung lebih *robust* terhadap terhadap *noise* dan *outlier* sehingga ia tidak terlalu bergantung terhadap data dengan perlakuan sehingga perubahan pada matriks evaluasi sangat beragam (Leone et al., 2019).

Pada algoritma *random forest* menghasilkan performa terbaik pada data tanpa perlakuan dengan stratifikasi berdasarkan provinsi dengan nilai rata-rata akurasi 0,893548; MCC 0,780065; AUPRC 0,889313 dan AUROC 0.945156. Nilai standar deviasi pada model ini juga mendekati 0 dibandingkan dengan model lain dengan perlakuan yang sama. Hal ini membuktikan bahwa model ini memiliki stabilitas terbaik. Model ini dihasilkan dari model pelatihan yang dihasilkan proses *hyperparameter tuning* sehingga dapat menghasilkan parameter terbaik untuk model pengujian.

Gambar 30. *Best Parameter Model Terbaik Algoritma Random Forest*

Hiperparameter	Variasi	Best Parameter
<i>N_estimators</i>	100, 200, 500, 800, 1200	100
<i>Max_depth</i>	None, 10, 20, 40, 60, 70	None
<i>min sample split</i>	2, 5, 10	10
<i>min sampel leaf</i>	1, 2, 4	2
<i>Max features</i>	Sart, log,	sart

<i>Max_features</i>	sqrt, log2	sqrt
<i>Bootstrap</i>	True, False	True

Gambar 31. *Confusion Matrix Best Model Random Forest*

XGBoost sendiri cenderung memiliki performa lebih baik dibandingkan *random forest* pada pembentukan model berdasarkan data hasil *preprocessing*. Pasalnya dibandingkan dengan perubahan matriks evaluasi pada *random forest*, *preprocessing* pada *XGBoost* lebih terlihat perbedaan. Pada stratifikasi berdasarkan target, matriks evaluasi terjadi perubahan

lebih besar dibandingkan dengan *random forest* dimana akurasi mengalami kenaikan sebesar 0,01613 dan MCC mengalami kenaikan sebesar 0,03415. Perbedaan performa *random forest* dan XGBoost terhadap data yang sudah di *preprocessing* dapat terjadi karena sensitifitas XGBoost terhadap distribusi dan skala fitur dibandingkan dengan *random forest* (Valentino *et al.*, 2025).

Pada algoritma XGBoost menghasilkan performa terbaik pada data *preprocessing* dengan stratifikasi berdasarkan provinsi juga dengan nilai rata-rata akurasi 0,883871; MCC 0,761677; AUPRC 0,895779 dan AUROC 0, 945855. Nilai standar deviasi pada model ini juga mendekati 0 dibandingkan dengan model lain dengan perlakuan yang sama. Hal ini membuktikan bahwa model ini memiliki stabilitas terbaik. Model ini dihasilkan dari model pelatihan yang dihasilkan proses *hyperparameter tuning* sehingga dapat menghasilkan parameter terbaik untuk model pengujian.

Tabel 19. *Best Parameter Model Terbaik Algoritma XGBoost*

Hiperparameter	Variasi	Best Parameter
<i>N_estimators</i>	100, 300, 500, 1000	300
<i>Max_depth</i>	3, 6, 10, 15	6
<i>learning_rate</i>	0.01, 0.05, 0.1, 0.2	0,01
<i>subsample</i>	0.6, 0.8, 1.0	0.6
<i>colsample_bytree</i>	0.6, 0.8, 1.0	0.6

Gambar 32. *Confusion Matrix Best Model XGBoost*

Gambaran lebih rinci mengenai prediksi model dapat dianalisis menggunakan *confusion matrix*. *Confusion matrix* menyajikan hasil model mengklasifikasikan dengan membandingkan kelas target sebenarnya dengan kelas target prediksi. Seluruh matriks

evaluasi yang ada dihitung berdasarkan *confusion matrix* dimana *confusion matrix* menjadi gambaran lengkap dan detailnya.

Confusion Matrix untuk model terbaik algoritma *random forest* terdapat di Gambar 33. Namun, *algoritma XGBoost* memiliki *confusion matrix* yang sama pada Gambar 34. Secara umum, sebagian besar puskesmas dapat diklasifikasikan dengan baik oleh model. Hal ini terlihat jelas bahwa dari total 62 puskesmas pada data uji, sebanyak 51 puskesmas dapat diidentifikasi dengan baik oleh model. Dimana 32 puskesmas dapat diidentifikasi dengan baik tidak memenuhi ketersediaan obat esensial sesuai dengan kenyataanya atau *true negative* dan

sebanyak 19 puskesmas diprediksi memenuhi ketersediaan obat esensial sesuai dengan kenyataan atau *true positive*. Walaupun begitu, sebanyak 11 puskesmas tidak teridentifikasi dengan baik. Sebanyak 9 puskesmas yang seharusnya tersedia obat esensial, tetapi terprediksi tidak tersedia atau *false negative* dan sebanyak 2 puskesmas terprediksi tersedia meskipun sebenarnya tidak tersedia atau *false positive*. Hal ini menandakan bahwa lebih banyak model cenderung memprediksi puskesmas tidak tersedia obat esensial walaupun kenyataannya tersedia. Maka dari itu, pada data ini *type II error* lebih mendominasi yang mana pada ketersediaan obat esensial berpotensi menyebabkan kondisi obat yang tidak terantisipasi (Fahmy, 2022).

Secara keseluruhan, performa *random forest* lebih baik dibandingkan *XGBoost*. Salah satunya adalah dapat terlihat pada sebagian besar matriks evaluasi akurasi dan MCC *random forest* lebih besar dibandingkan *XGBoost*, seperti pada strategi stratifikasi provinsi hasil *preprocessing* di mana pada *random forest* memiliki nilai akurasi dan MCC berturut-turut sebesar 0,870968 dan 0,73452 sedangkan dengan perlakuan yang sama *XGBoost* memiliki nilai sebesar 0,851613 dan 0,696736. Maka dari itu, *random forest* memiliki performa lebih baik dibandingkan *XGBoost* pada model yang memprediksi ketersediaan obat esensial di puskesmas Provinsi Daerah Istimewa Yogyakarta dan Provinsi Maluku. Namun, *XGBoost* tetap menjadi alternatif yang layak untuk data dengan *preprocessing* yang memadai menilai perbedaan antara kedua algoritma relatif kecil.

[CN1]Belum ada sitasi

Set data yang sudah melalui proses *preprocessing* akan masuk tahap selanjutnya, yaitu proses analisis data pembangunan model untuk mengetahui faktor yang memengaruhi ketersediaan obat esensial di Puskesmas Provinsi Daerah Istimewa Yogyakarta dan Provinsi Maluku. Penelitian ini memiliki variabel dependen atau target 34 obat esensial di Puskesmas

dengan variabel independen, seperti kategori puskesmas berdasarkan kemampuan pelayanan, akreditasi puskesmas, karakteristik wilayah puskesmas, dan lainnya.

Proses analisis data pembangunan model diawali dengan pemisahan data menjadi dua bagian, yaitu data pelatihan dan data pengujian. Pembagian ini dilakukan guna evaluasi kinerja model dan memastikan bahwa model tidak hanya baik pada data pelatihan tetapi baik pula pada data baru yang belum dilihat sebelumnya atau *overfitting* sehingga kinerja model lebih realistis dan general pada data yang belum terlihat sebelumnya. Pada penelitian ini, subset data dibagi sebanyak 80:20 dimana 80% data digunakan sebagai data pelatihan dan

Universitas Indonesia

20% data digunakan sebagai data pengujian. Pembagian data sebanyak 80:20 tersebut adalah rasio yang umum dan optimal untuk dataset kecil. Data pengujian pada *splitting data* sendiri akan digunakan sebagai data pembentukan dan melatih model mempelajari hubungan antara variabel independen dependen yang sesuai sedangkan data pengujian digunakan untuk memvalidasi kinerja model yang dihasilkan dari data pengujian untuk melihat apakah model bekerja baik pada data yang belum dilihat sebelumnya.

Pembagian data yang dilakukan didasarkan melalui 3 pendekatan stratifikasi data, yaitu stratifikasi berdasarkan variabel dependen atau target (y), stratifikasi berdasarkan provinsi, dan stratifikasi berdasarkan kemiripan karakteristiknya. Stratifikasi berdasarkan target dilakukan sebagai *baseline* karena umumnya model dibuat dengan menjaga distribusi kelas target dan menjaga keseimbangan kelas. Berbeda dengan stratifikasi berdasarkan target, stratifikasi berdasarkan provinsi akan membagi data pelatihan dan data pengujian dengan menjaga komposisi masing-masing provinsi, yaitu Daerah Istimewa Yogyakarta dan Maluku. Tahap ini melihat apakah faktor wilayah atau geografis menjadi berpengaruh terhadap kemampuan model memprediksi ketersediaan obat esensial di puskesmas. Selain itu, Stratifikasi berdasarkan kemiripan karakteristik juga dilakukan untuk mengelompokkan puskesmas yang didasari kemiripan pada variabel independen yang tersedia menggunakan metode cluster K-Means. Teknik *clustering* ini menjadi pilihan efektif untuk mengelompokkan kumpulan data berdasarkan tingkat kesamaan karakteristiknya. Selain itu, ia kerap digunakan karena kemudahan pengoperasiannya dalam mengklasterisasi dan kemudahan adaptasinya. K-Means Clustering akan mengelompokkan data ke dalam beberapa kelompok atau k berdasarkan jarak antar cluster. Penentuan k pada *k-means clustering* menjadi penting untuk dapat mengelompokkan data. Pada penelitian ini, sebanyak 5 cluster dipilih sebagai nilai k. Hal ini ditetapkan berdasarkan Peraturan Menteri Kesehatan Republik Indonesia Nomor 46 Tahun 2015 mengenai Akreditasi Puskesmas bahwa tingkat pencapaian puskesmas yang harus dicapai sama, yaitu 50% untuk puskesmas yang telah mencapai 50% dan 50% untuk puskesmas yang belum mencapai 50%.

dipenuhi guna meningkatkan mutu pelayanan pasien yang terbagi menjadi 5, yaitu dasar, madya, utama, paripurna, dan tidak terakreditasi dengan adanya penyesuaian ketersediaan data pada data Riset Fasilitas Kesehatan 2019. *Cluster* yang dibagi berdasarkan kemiripan ini akan dijalan menggunakan dua strategi, yaitu *intra-cluster* dan *ekstra-cluster*. *Intra-cluster* melakukan pembagian data pelatihan dan data pengujian dalam masing-masing cluster sehingga setiap cluster terwakilkan pada kedua subset data latih dan data uji. Strategi ini dilakukan guna menjaga distribusi data berdasarkan kemiripan karakteristik pada masing masing data. Sebaliknya, *ekstra-cluster* menerapkan pembagian data pelatihan dan data pengujian menggunakan *cluster* secara utuh sehingga dari 5 *cluster* yang terbentuk secara

Universitas Indonesia

bergantian 4 *cluster* menjadi data pelatihan dan 1 *cluster* menjadi data pengujian. Pendekatan ini selaras dengan pembagian data berdasarkan kelompok dimana Roberts et al. menuliskan bahwa strategi ini memberikan estimasi performa lebih realistis dibandingkan pembagian acak. Keseluruhan strategi stratifikasi ini dilakukan untuk melihat pengaruh struktur data terhadap kemampuan model memprediksi target. Dengan membandingkan ketiganya, penarikan kesimpulan metode pembagian data paling representatif sesuai ketersediaan data untuk mengetahui faktor yang memengaruhi ketersediaan obat esensial dapat dilakukan.

Pembelajaran model pada data pelatihan akan menggunakan dua algoritma *machine learning*, yaitu Random Forest dan Extreme Gradient Boosting. Dataset yang dimiliki peneliti berupa data berlabel, yaitu variabel target yang telah diketahui. Pada data pelatihan, model mempelajari hubungan variabel independen dan variabel target untuk dapat memutuskan atau memprediksi ketersediaan obat di puskesmas pada data baru atau data latih. Maka dari itu, pemilihan algoritma yang tergolong *supervised learning* dipilih karena *supervised learning* berlatih pada dataset dengan variabel target yang diketahui. Kedua algoritma dipilih juga karena kemampuannya untuk dapat memprediksi variabel target berupa kelas atau kategori tertentu atau berupa *classification* karena variabel target yang dimiliki adalah berupa kategori ketersediaan yang pasti, yaitu tersedia dan tidak tersedia bukan berupa nilai kontinu.

Model utama yang dipilih pada penelitian ini adalah *random forest classifier*. Algoritma *machine learning* ini dipilih karena keefektifannya menangani data besar dengan banyak variabel melihat dataset yang akan diteliti memiliki variabel independen setelah penanganan sebanyak 140 kolom dengan 309 baris atau puskesmas. Algoritma ini juga relatif cepat untuk dilatih dan diprediksi dan dapat digunakan secara langsung untuk dataset berdimensi tinggi. *Random Forest* bekerja dengan memprediksi variabel target data pengujian dengan membangun banyak pohon keputusan dan menggabungkan prediksinya untuk dapat menghasilkan prediksi yang stabil dan akurat. Pohon keputusan akan memilih pembagian

node terbaik dari variabel independen secara acak dan menggabungkan beberapa pohon keputusan dalam memprediksi. Langkah ini menjadikan masalah umum *machine learning*, yaitu *overfitting* dapat diatasi karena dapat mengurangi volatilitas dan bias. *Random Forest* juga dipilih karena ketahanannya pada data yang mengandung variasi, *noise*, ataupun pencilan. Penggunaan *random forest* juga dikarenakan kemampuannya untuk dapat mengidentifikasi tingkat pengaruh variabel independen terhadap keputusan prediksi sehingga sesuai dengan tujuan penelitian, yaitu untuk mengetahui faktor yang memengaruhi ketersediaan obat esensial di puskesmas.

Universitas Indonesia

Dengan metode serupa, tetapi dengan pendekatan berbeda, Extreme Gradient Boosting juga dilakukan untuk memprediksi ketersediaan obat esensial pada data pelatihan. Namun, XGBoost memiliki pendekatan yang berbeda dengan *random forest*. *Random forest* bekerja dengan *bagging* dari banyak pohon dan dari sampel data yang berbeda untuk dilakukan *majority voting*, tetapi XGBoost bekerja dengan membangun pohon secara berurutan dan melakukan *boosting* dengan memperbaiki error pada pembuatan pohon pertama saat membuat pohon keputusan berikutnya sehingga secara bertahap mengurangi kesalahan prediksi. Selain itu, XGBoost juga memiliki kemampuan baik untuk menangani berbagai dataset dengan adanya *noise*, missing value dengan data dengan berdimensi tinggi dan dapat mengatasi *overfitting* yang kerap terjadi pada model *machine learning*. Penggunaan algoritma XGBoost juga dilakukan untuk membandingkan kinerja dua algoritma dengan dua pendekatan *ensemble* yang berbeda untuk mengetahui metode paling sesuai dan menghasilkan informasi faktor yang memengaruhi lebih akurat.

Data pelatihan kedua algoritma akan dilakukan hiperparameter *tuning*. Langkah ini bertujuan untuk menghasilkan model dengan performa terbaik sehingga dapat meningkatkan akurasi, meningkatkan generalisasi, mencegah *overfitting* dan *underfitting*. Hiperparameter sendiri adalah parameter-parameter yang ditentukan sebelum proses *training* dilakukan untuk mengatur jalannya proses *training* dan terbentuknya model. Performa model dapat meningkat signifikan saat hiperparameter yang dipilih dengan benar, tetapi pemilihan hiperparameter yang buruk dapat menghasilkan model yang tidak efisien.

Dalam menemukan hiperparameter paling optimum, metode optimasi yang menjadi pilihan adalah *grid search* dibandingkan dengan *random search*. *Grid search* mencari parameter terbaik dari keseluruhan kemungkinan kombinasi hiperparameter yang ada sedangkan *random search* memiliki pendekatan berbeda dalam menentukan model terbaik, yaitu dengan mengambil sampel nilai hiperparameter yang ada. *Grid search* dipilih karena

mekanismesnya yang mencoba keseluruhan probabilitas kombinasi hiperparameter yang telah ditentukan sehingga model yang dihasilkan memiliki hiperparameter terbaik dari keseluruhan kombinasi hiperparameter dan model yang dihasilkan sangat stabil dengan nilai akurasi terbaik. Hal ini didukung dengan penelitian terdahulu yang membandingkan kedua metode pada dataset penyakit ginjal menggunakan algoritma *random forest* dengan *grid search* menghasilkan nilai matriks evaluasi yang sempurna dan lebih baik dibandingkan menggunakan *random search* (SITASI).

Guna melihat kualitas model yang terbentuk pada setiap kombinasi parameter, evaluasi model *5-fold cross validation*. Proses *cross validation* akan membagi data pelatihan menjadi 5

Universitas Indonesia

subset dan 5 subset tersebut akan bergantian menjadi data pelatihan dan data pengujian. Langkah ini bertujuan agar model dapat mempelajari pola yang terbentuk pada data yang tersedia dan juga memaksimalkan pembentukan model dengan menguji coba seluruh data sebagai pelatihan dan pengujian. Pemilihan jumlah lipatan atau k juga menentukan proses validasi. Dengan data set yang tidak terlalu besar dengan jumlah baris 309 dan fitur 140 menjadikan *cross validation* dengan $k = 5$ tepat untuk tetap menjaga proporsi seimbang antara data pelatihan dan data pengujian pada *cross validation*.

Pada algoritma *random forest* sendiri terdapat 6 jenis hiperparameter, yaitu *n_estimators* dengan 6 variasi, *bootstrap* dan *max_features* dengan 2 variasi, *max_depth* dengan 11 variasi, serta *min_samples_split* dan *min_samples_leaf* dengan 3 variasi. Dengan menggunakan metode *grid search* pada *cross validation*, pencarian model terbaik dengan hiperparameter paling optimal pada algoritma *random forest* menguji 2.376 kombinasi hiperparameter menggunakan *5-fold cross validation* sehingga pencarian model total dilakukan sebanyak 11.880 kali.

Algoritma XGBoost memiliki jenis hiperparameter yang berbeda dengan *random forest*. Hiperparameter XGBoost sendiri terdiri dari 5 jenis, yaitu *n_estimators*, *max_depth*, *learning_rate* dengan 4 variasi serta *subsample* dan *colsample_bytree* dengan 3 variasi. Maka dari itu, proses hiperparameter *tuning* algoritma ini akan menghasilkan 576 kombinasi hiperparameter yang akan dievaluasi. Dengan *5-fold cross validation* maka proses *fitting* pencarian model terbaik dengan hiperparameter optimal akan dilakukan 2.880 kali.

Universitas Indonesia

Pengaruh Strategi *Splitting* Data Terhadap Model

Splitting Data dilakukan dengan tiga strategi, yaitu stratifikasi berdasarkan target, provinsi dan *cluster* berdasarkan kemiripan karakteristik. Stratifikasi berdasarkan target memiliki performa standar sebagai baseline diantara ketiga strategi. Keseluruhan matriks evaluasinya konstan menjadi baseline dimana salah satunya terlihat pada AUROC baseline data XGBoost dengan nilai 0,87460 yang mana nilai ini lebih rendah dibandingkan strategi lainnya, yaitu provinsi sebesar 0,92145 dan *intra cluster* sebesar 0,892990.

Strategi berdasarkan *cluster* yang memanfaatkan *k-means* juga menghasilkan performa yang cukup baik. Pendekatan *intra cluster* memiliki performa lebih baik dibandingkan *ekstra cluster*. Hal ini konsisten pada seluruh data dan algoritma yang terjadi karena dari 5 cluster yang terbentuk, masing-masing bagian *cluster* terbagi menjadi data pelatihan dan data pengujian sehingga *best* model yang terbentuk mempelajari pola dengan baik pada data pelatihan dan data pengujian yang tersedia memiliki kemiripan karakteristik dengan data pelatihan. Berbanding terbalik dengan *ekstra cluster* yang konstan memiliki performa lebih buruk dibandingkan *intra cluster* karena data pengujian adalah data baru yang tidak dipelajari atau dilihat model pada proses training. Namun, *ekstra cluster* pada beberapa model memiliki performa yang tidak jauh berbeda dengan stratifikasi berdasarkan target walaupun tetap terjadi adanya penurunan pada *ekstra cluster* seperti pada data hasil *preprocessing* algoritma *random forest*. Hal ini menunjukkan bahwa model yang terbentuk tetap belajar pola generalisasi dari data pelatihan dan bukan hanya menghafal data karakteristik *cluster* pada data pelatihan.

Performa terbaik dimiliki oleh stratifikasi berdasarkan provinsi. Pada stratifikasi berdasarkan provinsi, konsisten pada keseluruhan matriks evaluasi memiliki performa terbaik dibandingkan ketiga strategi *splitting* data lainnya. Di mana *baseline* model *random forest*, Akurasi model mencapai 0,89355 dengan MCC 0,78006; AUPRC 0,88931 dan AUROC 0.94516. Akurasi yang tinggi menandakan bahwa 89,3% data dapat model prediksi dengan baik, dengan model yang terbentuk tidak hanya pada salah satu kelas yang diberikan dengan

baik dengan model yang terbentuk tidak bias pada salah satu kelas yang dibuktikan dengan MCC yang mendekati +1. Selain itu, AUPRC dan AUROC yang tinggi juga membuktikan bahwa model dapat memprediksi kelas positif dengan baik dan dapat membedakan dengan baik kedua kelas target. Performa terbaik yang dimiliki stratifikasi berdasarkan provinsi membuktikan bahwa adanya karakteristik yang jelas pada masing-masing provinsi Daerah Istimewa Yogyakarta dan Maluku dimana hal ini menguntungkan karena dapat mempertahankan pola yang relevan pada variabel independen terhadap ketersediaan obat.

Secara keseluruhan, kedua algoritma memberikan performa yang konsisten pada masing-masing strategi *splitting* data. *Splitting* data secara nyata memberikan perubahan

Universitas Indonesia

performa pada model di *random forest* maupun *XGBoost*. Performa tertinggi dimiliki oleh stratifikasi berdasarkan provinsi, diikuti oleh stratifikasi berdasarkan *cluster* dan stratifikasi berdasarkan target yang dijadikan target. Hal ini menunjukkan bahwa perbedaan karakteristik data pada data pelatihan dan data pengujian menjadi peran kunci untuk model dapat memprediksi ketersediaan obat dengan baik.

Pengaruh Preprocessing Terhadap Model

Secara garis besar, kedua algoritma memberikan performa yang baik dengan nilai yang berdekatan pada beberapa kondisi uji, tetapi tetap terdapat beberapa perbedaan antara kedua algoritma dalam merespon data. Pada *random forest* sendiri, Nilai rata-rata AUPRC dan AUROC-nya konstan lebih tinggi dibandingkan *XGBoost*. Hal ini menandakan bahwa *random forest* lebih andal untuk mendeteksi kelas tersedia pada data dan juga dapat membedakan kelas tersedia dan tidak tersedia dengan baik dibandingkan *XGBoost* sedangkan untuk matriks evaluasi lainnya.


Pada Gambar?? menunjukkan bahwa pada stratifikasi berdasarkan target (y), penerapan *preprocessing* menghasilkan perubahan performa yang kecil dibandingkan dengan *baseline*. Pada AUROC dan AUPRC hanya terjadi sedikit kenaikan, yaitu sebesar 0,00697 pada AUPRC dan 0,00173 pada AUROC. Selain itu, terjadi penurunan pada nilai MCC sebesar 0,0024 dan nilai akurasi yang bernilai tetap. Hasil ini menunjukkan bahwa *preprocessing* tidak menghasilkan peningkatan performa yang signifikan dan tidak bertindak konsisten pada seluruh matriks evaluasi. Namun, terjadi perubahan tampak jelas pada stratifikasi provinsi. Pasalnya terjadi penurunan pada sebagian besar matriks evaluasinya, seperti akurasi, MCC, dan AUROC. *Preprocessing* memberikan dampak penurunan pada sebagian besar matriks evaluasi. Di mana perlakuan Winsorization menggunakan IQR dengan merubah nilai pencilan memberikan perubahan pada matriks berupa sedikit penurunan performa. Hal ini


mengindikasikan bahwa variasi antarprovinsi memiliki informasi kuat membedakan ketersediaan obat esensial pada data pencilaan yang mengalami perubahan dengan winsorization (SITASI). Walaupun begitu, perubahan yang terjadi sangatlah kecil dan tidak bertindak konsisten karena AUPRC mengalami kenaikan yang mengindikasikan bahwa model dapat memprediksi kelas positif atau kelas tersedia dengan baik. Selain itu, *random forest* sendiri cenderung lebih *robust* terhadap terhadap *noise* dan *outlier* sehingga ia tidak terlalu bergantung terhadap data dengan perlakuan sehingga perubahan pada matriks evaluasi sangat beragam (SITASI).

Universitas Indonesia

Pada algoritma *random forest* menghasilkan performa terbaik pada data tanpa perlakuan dengan stratifikasi berdasarkan provinsi dengan nilai rata-rata akurasi 0,893548; MCC 0,780065; AUPRC 0,889313 dan AUROC 0.945156. Nilai standar deviasi pada model ini juga mendekati 0 dibandingkan dengan model lain dengan perlakuan yang sama. Hal ini membuktikan bahwa model ini memiliki stabilitas terbaik. Model ini dihasilkan dari model pelatihan yang dihasilkan proses *hyperparameter tuning* sehingga dapat menghasilkan parameter terbaik untuk model pengujian.

Hiperparameter	Variasi	Best Parameter
<i>N_estimators</i>	100, 200, 500, 800, 1200	100
<i>Max_depth</i>	None, 10, 20, 40, 60, 70	None
<i>min sample split</i>	2, 5, 10	10
<i>min sampel leaf</i>	1, 2, 4	2
<i>Max_features</i>	Sqrt, log ₂	sqrt
<i>Bootstrap</i>	True, False	True





Gambar??. *Confusion Matrix Best Model Random Forest*


XGBoost sendiri cenderung memiliki performa lebih baik dibandingkan *random forest* pada pembentukan model berdasarkan data hasil *preprocessing*. Pasalnya dibandingkan dengan perubahan matriks evaluasi pada *random forest*, *preprocessing* pada *XGBoost* lebih terlihat perbedaan. Pada stratifikasi berdasarkan target, matriks evaluasi terjadi perubahan

lebih besar dibandingkan dengan *random forest* dimana akurasi mengalami kenaikan sebesar 0,01613 dan MCC mengalami kenaikan sebesar 0,03415. Perbedaan performa *random forest* dan XGBoost terhadap data yang sudah di *preprocessing* dapat terjadi karena sensitifitas XGBoost terhadap distribusi dan skala fitur dibandingkan dengan *random forest* (SITASI).

Pada algoritma XGBoost menghasilkan performa terbaik pada data *preprocessing* dengan stratifikasi berdasarkan provinsi juga dengan nilai rata-rata akurasi 0,883871; MCC 0,761677; AUPRC 0,895779 dan AUROC 0,945855. Nilai standar deviasi pada model ini juga mendekati 0 dibandingkan dengan model lain dengan perlakuan yang sama. Hal ini membuktikan bahwa model ini memiliki stabilitas terbaik. Model ini dihasilkan dari model pelatihan yang dihasilkan proses *hyperparameter tuning* sehingga dapat menghasilkan parameter terbaik untuk model pengujian.

Hiperparameter	Variasi	Best Parameter
<i>N_estimators</i>	100, 300, 500, 1000	300
<i>Max_depth</i>	3, 6, 10, 15	6
<i>learning_rate</i>	0.01, 0.05, 0.1, 0.2	0,01
<i>subsample</i>	0.6, 0.8, 1.0	0.6
<i>colsample_bytree</i>	0.6, 0.8, 1.0	0.6





Gambar??. *Confusion Matrix Best Model XGBoost*

Universitas Indonesia

Gambaran lebih rinci mengenai prediksi model dapat dianalisis menggunakan *confusion matrix*. *Confusion matrix* menyajikan hasil model mengklasifikasikan dengan membandingkan kelas target sebenarnya dengan kelas target prediksi. Seluruh matriks evaluasi yang ada dihitung berdasarkan *confusion matrix* dimana *confusion matrix* menjadi gambaran lengkap dan detailnya.

Confusion Matrix untuk model terbaik algoritma *random forest* terdapat di gambar x. Namun, *algoritma XGBoost* memiliki *confusion matrix* yang sama. Secara umum, sebagian besar puskesmas dapat diklasifikasikan dengan baik oleh model. Hal ini terlihat jelas bahwa dari total 62 puskesmas pada data uji, sebanyak 51 puskesmas dapat diidentifikasi dengan baik oleh model. Dimana 32 puskesmas dapat diidentifikasi dengan baik tidak memenuhi ketersediaan obat esensial sesuai dengan kenyataannya atau *true negative* dan sebanyak 19 puskesmas diprediksi memenuhi ketersediaan obat esensial sesuai dengan kenyataan atau *true positive*. Walaupun begitu, sebanyak 11 puskesmas tidak teridentifikasi dengan baik. Sebanyak 9 puskesmas yang seharusnya tersedia obat esensial, tetapi terprediksi tidak tersedia atau *false negative* dan sebanyak 2 puskesmas terprediksi tersedia meskipun sebenarnya tidak tersedia atau *false positive*. Hal ini menandakan bahwa lebih banyak model cenderung memprediksi puskesmas tidak tersedia obat esensial walaupun kenyataannya tersedia. Maka dari itu, pada data ini *type II error* lebih mendominasi yang mana pada ketersediaan obat esensial berpotensi menyebabkan kondisi obat yang tidak terantisipasi (SITASI).


Secara keseluruhan, performa *random forest* lebih baik dibandingkan *XGBoost*. Salah satunya adalah dapat terlihat pada sebagian besar matriks evaluasi akurasi dan MCC *random forest* lebih besar dibandingkan *XGBoost*, seperti pada strategi stratifikasi provinsi hasil *preprocessing* di mana pada *random forest* memiliki nilai akurasi dan MCC berturut-turut sebesar 0,870968 dan 0,73452 sedangkan dengan perlakuan yang sama *XGBoost* memiliki nilai sebesar 0,851613 dan 0,696736. Maka dari itu, *random forest* memiliki performa lebih baik dibandingkan *XGBoost* pada model yang memprediksi ketersediaan obat esensial di

baik dibandingkan XGBoost pada model yang memprediksi ketersediaan obat esensial di puskesmas Provinsi Daerah Istimewa Yogyakarta dan Provinsi Maluku. Namun, XGBoost tetap menjadi alternatif yang layak untuk data dengan *preprocessing* yang memadai menilai perbedaan antara kedua algoritma relatif kecil.

4.4. Interpretasi Model



Hasil model terbaik pada algoritma *random forest* selanjutnya dianalisis *feature importance*. *Random Forest* menghasilkan model *black box*. Model *black box* yang dimaksud adalah cara kerja dan alasan model memprediksi hasil atau keputusan tidak diketahui dengan jelas. Maka dari itu, *Random Forest Feature importance* dapat menunjukkan fitur atau variabel

independen yang paling mempengaruhi atau memberi pengaruh model untuk menentukan variabel target atau ketersediaan obat esensial di satu puskesmas. Dimana tingkatan ini digambarkan dengan nilai yang mana semakin tinggi nilai *importance*-nya, maka semakin besar suatu fitur memberikan pengaruh terhadap ketersediaan obat esensial di puskesmas.



Pada gambar xx. terlihat jelas 10 variabel yang mempengaruhi faktor yang mempengaruhi ketersediaan obat esensial di puskesmas secara umum. Nilai *feature importance* tertinggi dimiliki oleh kode B4R14 atau jumlah kunjungan pasien rawat jalan, Sumber Dana BPJS dan kode B14R23 atau jumlah peserta PBI di puskesmas. Hal ini menunjukan bahwa jumlah pasien dan keuangan puskesmas memberikan pengaruh tertinggi terhadap model dalam menentukan tersedia atau tidaknya obat esensial di puskesmas. Namun, *feature importance* hanya dapat menunjukan fitur yang paling berkontribusi pada model tanpa mengetahui arah pengaruh fitur terhadap prediksi. Oleh karena itu, *Shapley* dilakukan untuk menganalisis lebih lanjut arah pengaruh faktor yang paling berpengaruh.





Gambar ??. Grafik *Shapley Global Importance*

Universitas Indonesia

SHAP (Shapley Additive exPlanations) sendiri adalah model *explainability* yang dapat mengurangi prediksi model menjadi kontribusi tiap fitur tidak pada model. Shapley dapat menunjukan fitur paling berpengaruh terhadap keputusan model pada keseluruhan data dengan *global importance*. Berdasarkan *random forest feature importance* yang sudah dilakukan sebelumnya menunjukan bahwa fitur yang memiliki bobot tertinggi dalam memberikan pengaruh terhadap model untuk memprediksi adalah jumlah kunjungan pasien rawat jalan, sumber dana BPJS, dan jumlah peserta PBI. Hal ini selaras dengan *explainability* yang dihasilkan oleh SHAP bahwa ketiga fitur tersebut adalah fitur terpenting untuk *best model* dalam memprediksi.

Pada gambar ?? terlampir grafik bar dan beeswarm untuk SHAP pada keseluruhan data. Pada fitur sumber dana BPJS sendiri menunjukan bahwa nilai SHAP variabel tersebut sebesar 0,0530. Fitur ini menunjukan bahwa sumber dana BPJS dengan kategori 3 atau Tidak memiliki dana BPJS dapat menurunkan ketersediaan obat esensial yang ditunjukan dengan titik-titik merah pada sumbu kiri sebaliknya pada sumber dana BPJS berupa Kapitasi dan Non-Kapitasi yang direpresentasikan dengan kategori 1 dapat meningkatkan ketersediaan obat esensial dengan *beeswarm* berupa titik-titik merah bernilai positif.


Pada kode B4R14 atau fitur jumlah kunjungan pasien rawat jalan memiliki nilai SHAP sebesar 0.0517 yang hanya berbeda tipis dengan sumber dana BPJS. Pada gambar ?? terlihat titik-titik merah berada pada sumbu x positif yang menandakan bahwa jumlah kunjungan pasien rawat jalan yang tinggi dapat meningkatkan ketersediaan obat esensial di puskesmas. Sebaliknya, puskesmas dengan jumlah kunjungan pasien rawat jalan yang rendah memiliki ketersediaan obat esensial tidak lebih baik dibandingkan puskesmas dengan kunjungan pasien rawat jalan lebih tinggi.

Fenomena yang terjadi pada jumlah kunjungan pasien rawat jalan juga selaras dengan kode B14R23 atau fitur jumlah pasien PBI. Dengan nilai SHAP sebesar 0.0476, ia menunjukkan bahwa jumlah pasien PBI yang tinggi dapat meningkatkan ketersediaan

memberikan makna bahwa jumlah pasien PBI yang tinggi dapat meningkatkan ketersediaan obat esensial. Hal ini berlaku sebaliknya bahwa jumlah pasien PBI yang rendah dapat menurunkan ketersediaan obat esensial di puskesmas.

Selain memiliki keuntungan melihat arah pengaruh fitur terhadap model prediksi secara global, SHAP juga dapat menjawab seberapa besar kontribusi dan arah fitur pada sebagian data observasi. Pendekatan ini disebut dengan *local importance*. Pada penelitian ini dengan metode SHAP, Kontribusi dan arah pengaruh fitur berfokus pada data masing-masing provinsi, yaitu Provinsi Daerah Istimewa Yogyakarta dan Provinsi Maluku.

Universitas Indonesia




Gambar ?? . Grafik *Local Importance* Provinsi Daerah Istimewa Yogyakarta

Pada gambar ?? terlihat grafik *local importance* untuk provinsi DIY. Dengan 3 variabel fitur yang sama menandakan bahwa ketiga fitur tersebut mempengaruhi model untuk memprediksi ketersediaan obat esensial di puskesmas pada provinsi Daerah Istimewa Yogyakarta. Pada kode B4R14 atau fitur jumlah kunjungan pasien rawat jalan memiliki nilai SHAP sebesar 0,0687 dengan representasi grafik *beeswarn* terlihat bahwa titik-titik yang merepresentasikan puskesmas berada pada sumbu kanan yang menandakan bahwa jumlah kunjungan pasien rawat jalan dapat meningkatkan ketersediaan obat esensial dimana titik-titik tersebut memiliki keragaman warna dari ungu hingga biru. Hal tersebut menandakan bahwa tidak ada kondisi yang dapat memprediksi ketersediaan obat secara langsung karena fitur ini konsisten pada kondisi apapun akan memberikan prediksi tersedianya obat esensial.

Peristiwa yang terjadi pada jumlah kunjungan pasien rawat jalan juga selaras dengan kode B14R23 atau fitur jumlah pasien PBI dengan nilai SHAP sebesar 0,066552. Grafik *beeswarn* pada fitur ini menunjukkan bahwa titik-titik memiliki warna yang beragam dan berpusat pada sumbu x kanan. Hal ini menandakan bahwa besar jumlah pasien PBI selalu mendukung prediksi bahwa obat esensial tersedia. Fenomena ini dapat terjadi karena pola yang terbentuk bukan hanya bergantung pada fitur ini sendiri, tetapi juga dipengaruhi oleh fitur lainnya sedangkan pada fitur sumber dana BPJS sendiri menunjukkan bahwa nilai SHAP variabel tersebut sebesar 0,0661. Fitur ini menunjukkan bahwa sumber dana BPJS, yaitu BPJS

Kapitasi dan Non-Kapitasi yang direpresentasikan dengan kategori 1 dapat meningkatkan ketersediaan obat esensial. Namun, kondisi ini tidak berlaku sebaliknya bahwa ketiadaan BPJS pada puskesmas dapat meningkatkan prediksi tersedianya obat esensial di puskesmas.

Universitas Indonesia



Gambar ?? . Grafik *Local Importance* Provinsi Maluku

Perlakuan pada provinsi Daerah Istimewa Yogyakarta juga dilakukan terhadap Provinsi Maluku. Namun terjadi perbedaan yang nyata pada hasil SHAP Provinsi Maluku dibandingkan DIY dan *global importance*. Pasalnya berdasarkan SHAP, model memprediksi ketersediaan pada puskesmas maluku dengan 3 fitur tertinggi, yaitu sumber dana BPJS, B4R14 atau jumlah pasien rawat jalan, dan B4R3 atau penggunaan SIM. Perubahan terjadi signifikan bagaimana model memprediksi ketersediaan pada puskesmas yang terletak di Provinsi Maluku dikarenakan penggunaan SIM lebih berperan dibandingkan jumlah peserta PBI.

Pada fitur sumber dana BPJS dengan data puskesmas Provinsi Maluku menunjukkan bahwa puskesmas tanpa BPJS membuat model memprediksi tidak tersedianya obat esensial. Hal ini ditunjukkan dengan titik-titik *beeswarm* berwarna merah yang berpusat pada SHAP *value* negatif. Hal ini berbanding terbalik dengan jumlah pasien rawat jalan dengan visualisasi titik-titik biru yang terdapat di SHAP *value negatif* yang menjelaskan bahwa semakin sedikit jumlah pasien rawat jalan, maka semakin tidak tersedianya obat esensial di puskesmas.

Perbedaan pada fitur yang mempengaruhi model memprediksi ketersediaan di Provinsi Maluku adalah kode B4R3 atau penggunaan SIM. Penggunaan SIM sendiri memiliki

3 kategori, yaitu Ya, ada jaringan antar ruang; Ya, tidak ada jaringan antar ruang; dan Tidak menggunakan komputer. Berdasarkan Gambar ??, Penggunaan SIM memberikan pengaruh tinggi terhadap keputusan prediksi model dimana puskesmas yang tidak menggunakan komputer cenderung diprediksi tidak tersedia obat esensial. Ketiga fitur menunjukkan pola yang serupa bahwa ketiganya mendukung prediksi bahwa obat esensial tidak tersedia dan tiba berlaku sebaliknya. Fenomena ini dapat terjadi karena pola yang terbentuk bukan hanya bergantung pada fitur-fitur ini sendiri, tetapi juga dipengaruhi oleh fitur lainnya

- Bahas Ablasi

4.5. Faktor Yang Paling Memengaruhi Ketersediaan Obat Esensial di Puskesmas

Ini bukan ya, as gambaran aja

Hasil penelitian ini juga sejalan dengan studi nasional mengenai ketersediaan obat esensial di Indonesia yang menunjukkan bahwa karakteristik fasilitas kesehatan dan tingkat pemanfaatan pelayanan merupakan faktor penting yang berkaitan dengan variasi ketersediaan obat antar-Puskesmas. Fasilitas kesehatan yang melayani populasi lebih besar umumnya memiliki kebutuhan logistik yang lebih tinggi dan sistem pengelolaan farmasi yang lebih aktif dibandingkan fasilitas dengan volume pelayanan yang rendah. Selain itu, ketersediaan obat yang baik diperlukan untuk menjaga keberlangsungan pelayanan kesehatan karena kekurangan obat dapat menghambat proses pengobatan serta menurunkan kualitas pelayanan yang diterima masyarakat.

Temuan SHAP dalam penelitian ini menunjukkan bahwa faktor yang berkaitan dengan **permintaan pelayanan kesehatan (service demand)** memiliki peran yang sangat besar dalam menentukan ketersediaan obat esensial. Ketika jumlah pasien rawat jalan meningkat, kebutuhan terhadap obat-obatan juga meningkat sehingga Puskesmas terdorong untuk memastikan ketersediaan stok yang memadai. Oleh karena itu, jumlah pasien rawat jalan tidak hanya merepresentasikan volume pelayanan kesehatan, tetapi juga menggambarkan tingkat kebutuhan obat yang harus dipenuhi oleh fasilitas kesehatan. Hasil ini mengindikasikan bahwa upaya peningkatan ketersediaan obat esensial perlu mempertimbangkan karakteristik beban pelayanan yang dihadapi masing-masing Puskesmas sehingga perencanaan dan distribusi obat dapat dilakukan secara lebih tepat sasaran.

Berdasarkan hasil *feature importance* pada model terbaik, variabel **jumlah pasien rawat inap** merupakan faktor yang paling berpengaruh terhadap prediksi ketersediaan obat

esensial di Puskesmas. Hasil ini menunjukkan bahwa Puskesmas dengan jumlah pasien rawat inap yang lebih tinggi cenderung memiliki ketersediaan obat esensial yang lebih baik dibandingkan Puskesmas dengan jumlah pasien rawat inap yang lebih rendah. Temuan tersebut mengindikasikan bahwa intensitas pemanfaatan layanan kesehatan memiliki hubungan yang erat dengan kesiapan fasilitas kesehatan dalam menyediakan obat-obatan yang dibutuhkan pasien. Tingginya jumlah pasien rawat inap mencerminkan besarnya kebutuhan pelayanan kesehatan yang harus dipenuhi oleh Puskesmas sehingga pengelolaan persediaan obat menjadi lebih diperhatikan untuk menjamin keberlangsungan pelayanan.

Universitas Indonesia

Dengan kata lain, semakin tinggi volume pelayanan yang diberikan, semakin besar pula tuntutan terhadap ketersediaan obat esensial sebagai komponen utama pelayanan kesehatan.

Temuan ini sejalan dengan penelitian terbaru mengenai sistem farmasi di Indonesia yang menunjukkan bahwa Puskesmas yang memiliki layanan rawat inap memiliki tingkat ketersediaan obat esensial yang lebih tinggi dibandingkan Puskesmas non-rawat inap. Dalam analisis terhadap 9.831 Puskesmas di Indonesia, keberadaan layanan rawat inap merupakan salah satu faktor yang secara signifikan berasosiasi dengan meningkatnya ketersediaan obat esensial. Hal ini menunjukkan bahwa fasilitas kesehatan dengan kapasitas pelayanan yang lebih besar cenderung memiliki sistem pengelolaan logistik, perencanaan kebutuhan obat, serta mekanisme pengadaan yang lebih baik sehingga mampu menjaga ketersediaan obat secara lebih konsisten.

Secara operasional, hubungan antara jumlah pasien rawat inap dan ketersediaan obat esensial dapat dijelaskan melalui mekanisme perencanaan kebutuhan obat. Puskesmas dengan jumlah pasien rawat inap yang tinggi akan menggunakan obat dalam jumlah yang lebih besar dan lebih beragam dibandingkan Puskesmas dengan volume pasien yang rendah. Kondisi ini mendorong fasilitas kesehatan untuk melakukan perencanaan stok yang lebih matang, pemantauan persediaan yang lebih rutin, serta pengadaan obat yang lebih terstruktur. Selain itu, tingginya jumlah pasien yang dilayani juga meningkatkan perhatian manajemen terhadap risiko *stockout* karena kekurangan obat dapat secara langsung mengganggu pelayanan pasien rawat inap yang memerlukan pemantauan dan terapi berkelanjutan. Oleh karena itu, jumlah pasien rawat inap tidak hanya merepresentasikan beban pelayanan, tetapi juga mencerminkan tingkat kesiapan sistem pengelolaan farmasi di fasilitas kesehatan.

Hasil penelitian ini juga relevan dengan konteks pelayanan kesehatan primer di Indonesia. Ketersediaan obat esensial merupakan salah satu indikator kesiapan pelayanan kesehatan, sedangkan tingginya jumlah pasien rawat inap menunjukkan bahwa Puskesmas berperan sebagai fasilitas kesehatan yang aktif diandalkan masyarakat. Fasilitas yang

berperan sebagai fasilitas kesehatan yang aktif digunakan masyarakat. Fasilitas yang melayani lebih banyak pasien akan memiliki kebutuhan yang lebih besar untuk menjaga kontinuitas pelayanan sehingga ketersediaan obat menjadi prioritas operasional. Dengan demikian, tingginya jumlah pasien rawat inap dapat dipandang sebagai indikator tidak langsung dari kapasitas pelayanan dan kemampuan manajemen fasilitas kesehatan dalam mempertahankan ketersediaan obat esensial.

4.6. Keterbatasan Penelitian

hanya untuk kedua provinsi ini

Universitas Indonesia

Kenapa RF lebih bagus secara rata rata (keseluruhan) dibandingkan XGBoost

Kenapa provinsi RF turun tapi XGBoost malah naik setelah preprocessing

Universitas Indonesia

Setelah model terbaik diperoleh, dilakukan analisis feature importance untuk mengidentifikasi variabel yang paling berkontribusi dalam proses prediksi ketersediaan obat esensial. Feature importance menggambarkan seberapa besar kontribusi suatu variabel dalam pembentukan keputusan model selama proses klasifikasi. Semakin tinggi nilai importance, semakin besar peran variabel tersebut dalam membedakan Puskesmas dengan ketersediaan obat esensial yang tinggi maupun rendah.

Berdasarkan Gambar X, variabel yang memiliki nilai feature importance tertinggi adalah jumlah tenaga kefarmasian, diikuti oleh jumlah kunjungan pasien, status akreditasi, layanan rawat inap, dan ketersediaan laboratorium. Hasil ini menunjukkan bahwa faktor sumber daya manusia, karakteristik pelayanan kesehatan, dan kapasitas fasilitas kesehatan merupakan komponen yang paling sering dimanfaatkan model dalam memprediksi ketersediaan obat esensial.

Namun demikian, feature importance hanya menunjukkan tingkat kepentingan relatif suatu variabel dalam model dan belum dapat menjelaskan arah pengaruh variabel tersebut terhadap prediksi. Oleh karena itu, dilakukan analisis menggunakan SHAP untuk memahami bagaimana perubahan nilai setiap variabel memengaruhi probabilitas ketersediaan obat esensial.

Analisis SHAP (SHapley Additive exPlanations) digunakan untuk menjelaskan kontribusi masing-masing variabel terhadap prediksi model. Berbeda dengan feature importance yang hanya menunjukkan tingkat kepentingan variabel, SHAP mampu menjelaskan arah dan besar pengaruh setiap variabel terhadap probabilitas ketersediaan obat esensial. Pada grafik SHAP, titik berwarna merah menunjukkan nilai variabel yang tinggi, sedangkan titik berwarna biru menunjukkan nilai variabel yang rendah.

Variabel jumlah tenaga kefarmasian menunjukkan pola bahwa nilai yang lebih tinggi cenderung menghasilkan nilai SHAP positif. Hal ini menunjukkan bahwa Puskesmas dengan jumlah tenaga kefarmasian yang lebih banyak memiliki probabilitas lebih tinggi untuk mempertahankan ketersediaan obat esensial. Temuan ini sejalan dengan peran tenaga kefarmasian dalam perencanaan kebutuhan obat, pengadaan, penyimpanan, serta pemantauan stok sehingga keberadaannya berkontribusi terhadap keberlangsungan ketersediaan obat.

Universitas Indonesia

Variabel jumlah kunjungan pasien menunjukkan pola yang berbeda. Nilai yang tinggi cenderung berkaitan dengan nilai SHAP negatif, yang mengindikasikan penurunan probabilitas ketersediaan obat esensial. Kondisi ini dapat disebabkan oleh meningkatnya kebutuhan obat pada Puskesmas dengan beban pelayanan yang tinggi sehingga risiko kekosongan stok menjadi lebih besar apabila tidak diimbangi dengan sistem pengelolaan persediaan yang memadai.

Status akreditasi juga menunjukkan kontribusi yang cukup besar terhadap prediksi model. Puskesmas dengan tingkat akreditasi yang lebih baik cenderung memiliki nilai SHAP positif, yang menunjukkan peluang ketersediaan obat esensial yang lebih tinggi. Hal ini dapat terjadi karena akreditasi umumnya berkaitan dengan kualitas tata kelola, dokumentasi, dan pengendalian mutu pelayanan kesehatan, termasuk pengelolaan logistik farmasi.

Secara keseluruhan, hasil SHAP menunjukkan bahwa pengaruh variabel terhadap ketersediaan obat esensial tidak hanya ditentukan oleh tingkat kepentingannya dalam model, tetapi juga oleh arah hubungan yang dimiliki masing-masing variabel. Beberapa variabel meningkatkan probabilitas ketersediaan obat esensial ketika nilainya tinggi, sedangkan variabel lain justru berkaitan dengan peningkatan risiko ketidaktersediaan obat.

Universitas Indonesia

Perbandingan Algoritma *Random Forest* dan *XGBoost*

Secara garis besar, kedua algoritma memberikan performa yang baik dengan nilai yang berdekatan pada beberapa kondisi uji. tetapi tetap terdapat beberapa perbedaan antara kedua algoritma dalam merespon data. Pada *random forest* sendiri, Nilai rata-rata AUPRC dan AUROC-nya konstan lebih tinggi dibandingkan *XGBoost*. Hal ini menandakan bahwa *random forest* lebih andal untuk mendeteksi kelas tersedia pada data dan juga dapat membedakan kelas tersedia dan tidak tersedia dengan baik dibandingkan *XGBoost*. Sedangkan *XGBoost* sendiri cenderung memiliki performa lebih baik dibandingkan *random forest* pada pembentukan model berdasarkan data hasil *preprocessing*

nilai rata rata RF lebih tinggi → RF lebih baik membedakan kelas + n - dan andal deteksi kelas +

kedua model relatif sebanding stabilitas. gaada yang konsisten lebih stabil → keduanya sama sama sensitif perubahan pembagian data (stratifikasi) dan ga benar benar lebih robust dari sisi stabilitas

Random Forest cenderung lebih robust dan tidak terlalu bergantung pada perlakuan terhadap data, sehingga bahkan tanpa preprocessing pun sudah mampu menghasilkan performa yang baik. XGBoost di sisi lain lebih sensitif terhadap kualitas dan distribusi fitur, sehingga lebih banyak diuntungkan ketika data sudah diproses terlebih dahulu.

performa lebih tinggi di lebih banyak kondisi dan metrik. Namun XGBoost tetap merupakan alternatif yang layak, terutama dalam skenario di mana data telah melalui preprocessing yang memadai. Perbedaan antara keduanya yang relatif kecil juga mengindikasikan bahwa **pemilihan strategi splitting dan preprocessing** berkontribusi lebih besar terhadap performa akhir dibandingkan pemilihan model itu sendiri.

Universitas Indonesia

- pembagian train-test. train buat apa dan testing buat apa
 - Dataset kemudian dibagi menjadi data latih (training set) dan data uji (testing set). Data latih digunakan untuk melatih model machine learning dalam mempelajari pola hubungan antar variabel, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data yang belum pernah dilihat sebelumnya. Pembagian data dilakukan untuk menghindari overfitting dan memastikan model mampu melakukan generalisasi dengan baik.
 - Selain pembagian data secara umum, penelitian ini juga melakukan beberapa strategi stratifikasi data, yaitu stratifikasi berdasarkan target (stratify y), provinsi, dan cluster KMeans. Pendekatan tersebut dilakukan untuk menjaga distribusi karakteristik data pada proses pelatihan dan pengujian model sehingga evaluasi model menjadi lebih representatif.
 - Metode ini sering digunakan untuk memecahkan masalah dengan cara mengelompokkan data ke dalam beberapa kelompok, yang dikenal sebagai 'K', berdasarkan jarak terkecil antar cluster.
 - Dalam analisis data mining, algoritma K-Means berperan dalam membangun model yang dapat mempengaruhi proses pengambilan keputusan (Taryadi, 2022). Data mining adalah suatu teknik yang digunakan untuk mengidentifikasi informasi secara menyeluruh dari berbagai dataset besar, dengan tujuan untuk memperoleh pengetahuan baru [(R et al., 2022).
 - Selain pembagian data secara umum, penelitian ini juga melakukan beberapa strategi stratifikasi data, yaitu stratifikasi berdasarkan target (stratify y), provinsi, dan cluster KMeans. Pendekatan tersebut dilakukan untuk menjaga

distribusi karakteristik data pada proses pelatihan dan pengujian model sehingga evaluasi model menjadi lebih representatif.

- Divide data into training data and testing data using k-fold cross-validation. The data used in the model formation process is referred to as training data, and the data used to validate the model is referred to as testing data. A dataset is divided into k subsets with the same number of k-fold cross-validation. Each subset will take turns being testing. The calculation of the average of all accuracy results for all folds is a cross validation assessment of the overall

Universitas Indonesia

model accuracy [23]. Meanwhile, in this study, the data is divided into 5 folds or 5 subsets. The model in the classification will be tested 5 times using 5 tests obtained (50 replications).

- cross validation 5x
 - Penelitian ini menggunakan 5-fold cross validation untuk meningkatkan stabilitas evaluasi model. Pada metode ini, dataset dibagi menjadi lima bagian, di mana empat bagian digunakan sebagai data latih dan satu bagian digunakan sebagai data uji secara bergantian hingga seluruh bagian pernah menjadi data uji. Hasil evaluasi kemudian dirata-ratakan untuk memperoleh performa model yang lebih stabil dan mengurangi bias akibat pembagian data tertentu.
- Random Forest. Kenapa pake ini
 - Algoritma Random Forest digunakan pada penelitian ini karena mampu menangani data dengan jumlah fitur yang cukup banyak serta memiliki kemampuan yang baik dalam mengurangi overfitting melalui kombinasi banyak decision tree. Selain itu, Random Forest juga mampu mengidentifikasi tingkat kepentingan fitur (feature importance) sehingga sesuai digunakan untuk analisis faktor yang memengaruhi ketersediaan obat.
- XGBOOST Kenapa pake ini
 - Selain Random Forest, penelitian ini juga menggunakan algoritma XGBoost yang merupakan metode ensemble berbasis boosting. XGBoost dipilih karena memiliki performa yang baik dalam menangani data kompleks serta mampu meningkatkan akurasi model melalui proses pembelajaran bertahap dari kesalahan model sebelumnya.

Selain itu, Random Forest juga mampu mengidentifikasi tingkat kepentingan fitur (feature importance) sehingga sesuai digunakan untuk analisis faktor yang memengaruhi ketersediaan

obat.

Meskipun penelitian ini telah melakukan penanganan outlier menggunakan metode IQR dan winsorization pada tahap preprocessing, Random Forest tetap dipilih karena memiliki ketahanan yang baik terhadap data yang masih mengandung variasi, noise, maupun outlier ringan yang mungkin masih tersisa setelah proses pembersihan data. Selain itu, Random Forest mampu menangani data berdimensi tinggi, memodelkan hubungan nonlinier antar variabel, serta relatif tidak sensitif terhadap perubahan hiperparameter dibandingkan metode pohon keputusan tunggal.

Universitas Indonesia